## 33. A BOYER-MOORE ALGORITMUS EGY VÁLTOZATA


Az egyszerű mintaillesztés műveletigénye legjobb esetben *n*-es volt; most ezen próbálunk javítani. Az algoritmus, amelyet ismertetünk A *Boyer-Moore* mintaillesztés több javasolt változata körül az, amelyiknek a "*Quick Search*" (*QS*) nevet adta a szerzője (*Horspool*).

Az előző fejezetben ismertetett *KMP* eljárás a mintán belüli karaktersorozat előzetes elemzése révén jutott hatékony mintaillesztéshez. A *QS* algoritmus más stratégiát követ. Ha az illeszkedés elromlik, akkor a szövegnek *a minta utáni első karakterét* (*S*[*k*+*m*+1]) vizsgálja. Ennek a karakternek a függvényében dönti el, hogy hány pozícióval lépteti jobbra a mintát.

## 33.1. A QS eljárás működési elve


Az eljárás működése során az alábbi két esetet különböztetjük meg:

1. A szöveg minta utáni első karaktere nem fordul elő a mintában, azaz S[k+m+1] ∉ M. Ekkor bármely olyan illesztés sikertelen lenne, ahol az S[k+m+1] pozíció fedésben lenne a mintával. Tehát ezt a pozíciót "átugorhatjuk" a mintával, és a szöveg következő, S[k+m+2] indexű karakterétől kezdhetjük újra, a minta elejétől kezdve, az illeszkedés vizsgálatát. Ezt az esetet illusztrálja a 33.1. ábra.



**33.1. ábra.** Példa: a szöveg minta utáni első karaktere nem fordul elő a mintában

2. A szöveg minta utáni *első* karaktere *előfordul* a mintában, azaz *S*[*k* + *m* + 1] ∈ *M*. Ekkor vegyük a mintabeli előfordulások közül *jobbról* az *elsőt* (balról, a minta elejétől számítva az utolsót) és annyi pozícióval léptessük jobbra a mintát, hogy ez a mintabeli karakter fedésbe kerüljön a szöveg *S*[*k* + *m* + 1] karakterével, majd a minta elejétől kezdve vizsgáljuk meg újra az illeszkedést. Ez az eset látható a 33.2. ábrán.



33.2. ábra. Példa - szöveg minta utáni első karaktere előfordul a mintában

Az S[k+m+1] karakternek azért kell jobbról az első mintabeli előfordulását tekinteni, mert ha létezik egy ettől balra lévő előfordulás is, és amennyiben azt választanánk, akkor esetleg átlépnénk egy jó illeszkedést, mint ahogyan a 33.3. ábrán látható esetben ez megtörténik. Akárcsak a KMP algoritmusnál, itt is követni kell az óvatos legkisebb biztonságos eltolás elvét.

							S	[k+m+	+m+1]					
S	A	В	В	A	Α	С	В	C	D	373				
M	A	A	e	В	С	D								
	ha ide ugrunk			М	Α	A	¢	В	С	D				
		2 - 1	М	A	A	С	В	С	D		ezt az ill	le szke dé	st átu	gorjuk

33.3. ábra. Példa egy jó illeszkedés átugrására

## 31.2. A QS algoritmus

A QS algoritmusnak is a lényegi részét adja a minta alkalmas eltolásának ismételt végrehajtása. Az eltolás mértékének meghatározása bevezetjük a *shift* függvényt, amely az ábécé minden betűjére megadja az eltolás nagyságát, ha az illeszkedés elromlása esetén az illető betű lenne a szöveg minta utáni első karaktere.


Definíció: 
$$shift: H \to [1..m+1]$$
 
$$shift(x) = \begin{cases} m+1 &, \text{ ha } x \notin M \\ m-j+1 &, \text{ ha } M[j] = x \land \forall i \in [j+1..m]: M[i] \neq x \end{cases}$$

Megjegyzések:

- A definicióban is jól láthatóan elválik a fent említett két eset.
- Mivel a *shift* függvény csak a mintától függ, értékeit előre kiszámíthatjuk, és eltárolhatjuk egy vektorba, amit az ábécé betűivel indexelünk.


Most nézzük a *shift* függvény értékeinek a kiszámítására szolgáló *initshift* eljárást, amelynek algoritmusát a 33.4. ábra szemlélteti..

Az első ciklus feltölti a *shift* tömböt az *m*+1 értékkel. A második ciklus adja meg a minta össze betűjére – a jobbról az első mintabeli elfordulásának megfelelő – ugrás nagyságát. Azért balról-jobbra megyünk végig a mintán, hogy a többször előforduló betűk esetén az utolsó (jobbról az első) előfordulásnak megfelelő léptetést jegyezzük fel.



33.4. ábra. Az inshift eljárás algoritmusa

A *QS* algoritmus a *shift* függvény értékeinek kiszámításával kezdődik, majd *k* eltolásokkal próbáljuk illeszteni a mintát. Amennyiben az illeszkedés elromlik, akkor a *shift* függvénynek megfelelően változtatjuk az eltolás mértékét. (Ügyelnünk kell arra is, hogy amikor a mintát a szöveg végére illesztjük, és az illeszkedés elromlik, akkor ne olvassunk túl a szövegen.)



33.5. ábra. A QS mintaillesztés algoritmusa

A *műveletigény* meghatározását a *legjobb esettel* kezdjük. Ha a minta olyan karakterekből áll, amelyek nem fordulnak elő a szövegben, akkor már a minta első karakterénél elromlik az illeszkedés. Továbbá, ha a szövegben a minta utáni karakter nem fordul elő a mintában, akkor azt átugorhatjuk. Ezt az esetet illusztrálja a 33.6. ábra.

Α	Α	Α	$\mathbf{A}$	Α	Α	A	Α	Α	Α	Α	Α	Α		
В	В	В												
				В	В	В								
								В	В	В				
												В	В	В

**33.6. ábra.** A *QS* algoritmus számára legkedvezőbb eset

A legkedvezőbb esetben a műveletigény:

$$m\ddot{O}(n,m) = \Theta\left(\frac{n}{m+1}\right)$$

A legrosszabb esetben egyrészt a minta végén romlik el az illeszkedés, másrészt mindig csak kicsiket tudunk ugrani. Ilyen esetet mutat a 33.7. ábra.

A	Α	Α	Α	Α	Α	Α	Α	Α	Α	Α	Α	Α	
Α	Α	Á	В	(0 T			9 93				83 SE		
		Α	A	À	В								
				A	Α	Α	В						
						Α	A	Α	В				
								Α	Α	A	В		
										Α	Α	A	В

33.7. ábra. A QS algoritmus számra legkedvezőtlenebb eset

A legkedvezőtlenebb esetben a műveletigény:

$$M\ddot{O}(n) = \Theta(n * m)$$

A *QS* algoritmust *szekvenciális* input fájlra, illetve más, közvetlenül nem indexelhető sorozatra, csak *puffer* használatával lehet alkalmazni, mivel – ahogyan az a legrosszabb esetben is látható – szükség lehet a szövegben való visszalépésre.