

Formális nyelvek és a fordítóprogramok alapjai

2. előadás

Előadó: Nagy Sára, mesteroktató
Algoritmusok és Alkalmazásaik Tanszék

Emlékeztető:

V - ábécé, jelek nem üres véges halmaza;

V^* - az adott jelkészlet felett értelmezett összes szó;

$L \subseteq V^*$ - formális nyelv, szavak halmaza.

Emlékeztető:

Definíció: Grammatikának (nyelvtannak) a következő négyest nevezzük:

$G=(N,T,P,S)$

- N a nemterminális ábácé,
- T a terminálisok ábécéje,
- P az átírási szabályok véges halmaza,
- S a kezdőszimbólum.

Emlékeztető:


- ▶ N és T diszjunkt halmazok, azaz $N \cap T = \emptyset$.
- ▶ $S \in N$, kezdőszimbólum.
- ▶ A szabályok $p \rightarrow q$ alakúak, ahol $p \in (N \cup T)^* N (N \cup T)^*$, $q \in (N \cup T)^*$ és p jelöli a szabály baloldalát, q a jobboldalát, \rightarrow a két oldalt elválasztó jel.
- ▶ A szabályok baloldala kötelezően tartalmaz legalább egy nemterminális szimbólumot.
- ▶ $(N \cup T)^*$ elemeit *mondatformáknak* nevezzük.

Grammatika által generált nyelv

Minden olyan szó, amely közvetetten levezethető a kezdőszimbólumból.

$$L(G) := \{ u \in T^* \mid S \xRightarrow[G]{*} u \}$$

Noam Chomsky (született: 1928)



Noam Chomsky amerikai nyelvész, a Massachusetts Institute of Technology professzora, a generatív nyelvtan elméletének megalkotója, filozófus, politikai aktivista, előadó és lektor. Kidolgozója a róla elnevezett Chomsky-hierarchiának. (Wikipédia)

Chomsky féle grammatika típusok

Definíció: A $G = (N, T, P, S)$ grammatika i -típusú ($i = 0, 1, 2, 3$), ha P szabályhalmazára teljesülnek a következők:

- $i = 0$: Nincs korlátozás.
- $i = 1$: P minden szabálya $u_1 A u_2 \rightarrow u_1 v u_2$ alakú, ahol $u_1, u_2, v \in (N \cup T)^*$, $A \in N$, és $v \neq \varepsilon$, kivéve az $S \rightarrow \varepsilon$ alakú szabályt, de ekkor S nem fordul elő egyetlen szabály jobb oldalán sem
(Ezt "Korlátozott ε szabály"-nak, röviden: KES szabálynak hívjuk.)
- $i = 2$: P minden szabálya $A \rightarrow v$ alakú, ahol $A \in N$, $v \in (N \cup T)^*$.
- $i = 3$: P minden szabálya vagy $A \rightarrow u B$ vagy $A \rightarrow u$ alakú, ahol $A, B \in N$ és $u \in T^*$.

Chomsky féle grammatika típusok

Jelölje \mathcal{G}_i az i -típusú grammatikák halmazát.

A grammatikák alakjából következik, hogy

$$\mathcal{G}_i \subseteq \mathcal{G}_0, \text{ ahol } i=1,2,3.$$

$$\mathcal{G}_3 \subseteq \mathcal{G}_2$$

Nyelvek típusai

Egy L nyelvet i -típusúnak nevezünk ($i \in \{0,1,2,3\}$), ha létezik olyan i -típusú grammatika, ami az L nyelvet generálja.


Jelölje \mathcal{L}_i az i -típusú nyelvek halmazát.
(Nyelvcsalád.)

Chomsky féle hierarchia

$$\mathcal{L}_3 \subseteq \mathcal{L}_2 \subseteq \mathcal{L}_1 \subseteq \mathcal{L}_0$$

Pontosabban valódi tartalmazás van

$$\mathcal{L}_3 \subset \mathcal{L}_2 \subset \mathcal{L}_1 \subset \mathcal{L}_0$$



Chomsky féle grammatika típusok

Típus	Alaptípus szabályai	Speciális alakok szabályai	Normál forma szabályai
0.	Nincs korlátozás.	$p \rightarrow q$, ahol $p \in N^+$, $q \in (N \cup T)^*$	
1.	$u_1 A u_2 \rightarrow u_1 v u_2$, ahol $u_1, u_2, v \in (N \cup T)^*$, $A \in N$, és $v \neq \varepsilon$, kivéve az $S \rightarrow \varepsilon$, de ekkor S nem fordul elő egyetlen szabály jobb oldalán sem. (környezetfüggő grammatika)	$p \rightarrow q$, ahol $l(p) \leq l(q)$ kivéve az $S \rightarrow \varepsilon$, de ekkor S nem fordul elő egyetlen szabály jobb oldalán sem. (hosszúság nemcsökkentő grammatika)	Kuroda normál forma $A \rightarrow a$ vagy $A \rightarrow B$ vagy $A \rightarrow BC$ vagy $AB \rightarrow CD$ alakúak a szabályok, ahol $a \in T$ és $A, B, C, D \in N$, kivéve az $S \rightarrow \varepsilon$, de ekkor S nem fordul elő egyetlen szabály jobb oldalán sem.
2.	$A \rightarrow v$, ahol $v \in (N \cup T)^*$, $A \in N$ (környezetfüggetlen grammatika)	$A \rightarrow v$, ahol $v \in (N \cup T)^*$, $A \in N$ és $v \neq \varepsilon$, kivéve az $S \rightarrow \varepsilon$, de ekkor S nem fordul elő egyetlen szabály jobb oldalán sem.	Chomsky normál forma $A \rightarrow a$ vagy $A \rightarrow BC$ alakúak a szabályok, ahol $a \in T$ és $A, B, C \in N$, kivéve az $S \rightarrow \varepsilon$, de ekkor S nem fordul elő egyetlen szabály jobb oldalán sem.
3.	$A \rightarrow uB$ vagy $A \rightarrow u$, ahol $u \in T^*$, $A, B \in N$ (reguláris grammatika)	$A \rightarrow aB$ vagy $A \rightarrow a$, ahol $a \in T$, és $A, B \in N$, kivéve az $S \rightarrow \varepsilon$, de ekkor S nem fordul elő egyetlen szabály jobb oldalán sem.	3-as normál forma $A \rightarrow aB$ vagy $A \rightarrow \varepsilon$, ahol $a \in T$, és $A, B \in N$.

Példa

$$L = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \geq 0 \}$$

$G_1 = (\{S', S, A, B\}, \{a, b\}, P, S')$ egy grammatika.

$P_1: S' \rightarrow \varepsilon$	KES
$S' \rightarrow S$	0,1,2,3-as típusú szabály
$S \rightarrow ASB$	0,1,2-es típusú szabály
$S \rightarrow AB$	0,1,2-es típusú szabály
$AB \rightarrow BA$	0-s típusú szabály
$A \rightarrow a$	0,1,2,3-as típusú szabály
$B \rightarrow b$	0,1,2,3-as típusú szabály

A G_1 grammatika 0-s típusú. $G_1 \in \mathcal{G}_0$

Példa

$$L = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \geq 0 \}$$

$G_2 = (\{S,A,B\}, \{a,b\}, P, S)$ egy grammatika.

$$P_2: S \rightarrow aSbS$$

$$S \rightarrow bSaS$$

$$S \rightarrow \varepsilon$$

Állítás: $L = L(G_2)$.

Bizonyítás: Mivel ,a' és ,b' együtt generálódik, ezért $L(G_2) \subseteq L$.

Kérdés, hogy minden L beli szó generálható-e, azaz $L \subseteq L(G_2)$?

Példa folytatása

Kérdés, hogy minden L beli szó generálható-e, azaz $L \subseteq L(G_2)$?

Minden szó hossza páros, azaz $\ell(u) \geq 2 \cdot k$, ahol $k \in \mathbb{N}$.

A tartalmazás k szerinti teljes indukcióval bizonyítható.

$k=1$ esetén látható, hogy $S \xRightarrow{G} aSbS \xRightarrow{G}^* ab$ és $S \xRightarrow{G} bSaS \xRightarrow{G}^* ba$

Tegyük fel, hogy a $2k$ hosszú szavakat le tudjuk vezetni. Legyen $\ell(u) = 2 \cdot (k+1)$.

Ha az u szó $,a'$ -val kezdődik, akkor biztosan van egy $,b'$ párja, azaz

$u = vw$, ahol v az első olyan prefix, hogy $v \in L$, azaz $\ell_a(v) = \ell_b(v)$ és $v = axb$.

Ekkor $x, w \in L$ és $2 \cdot k \geq \ell(x) \geq 0$ és $2 \cdot k \geq \ell(w) \geq 0$.

Így $S \xRightarrow{G} aSbS \xRightarrow{G}^* axbS \xRightarrow{G}^* axbw$, ahol teljes indukciót alkalmazhatunk x és w levezetésére.

Ha $,b'$ -vel kezdődne a szó, akkor hasonlóan járunk el.

Példa

$$L = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \geq 0 \}$$

$G_2 = (\{S,A,B\}, \{a,b\}, P, S)$ egy grammatika.

P_2 : $S \rightarrow aSbS$ 0,1,2-es típusú szabály

$S \rightarrow bSaS$ 0,1,2-es típusú szabály

$S \rightarrow \varepsilon$ 0,2,3-as típusú szabály (nem KES)

A G_2 grammatika 2-es típusú. $G_2 \in \mathcal{G}_2$

$L(G_1) = L(G_2)$, azaz a két grammatika ekvivalens.

Az L nyelv 2-es típusú, mert van hozzá 2-es típusú grammatika.

$$L \in \mathcal{L}_2$$

Lehet, hogy $L \in \mathcal{L}_3$?

Válasz: nem. Bizonyítás később.

Chomsky féle grammatika típusok

Definíció: A $G = (N, T, P, S)$ grammatika i -típusú ($i = 0, 1, 2, 3$), ha P szabályhalmazára teljesülnek a következők:

- $i = 0$: Nincs korlátozás.
- $i = 1$: P minden szabálya $u_1 A u_2 \rightarrow u_1 v u_2$ alakú,
ahol $u_1, u_2, v \in (N \cup T)^*$, $A \in N$, és $v \neq \varepsilon$,
kivéve az $S \rightarrow \varepsilon$ alakú szabályt, de ekkor S nem fordul elő egyetlen szabály jobboldalán sem (röviden: KES)
- $i = 2$: P minden szabálya $A \rightarrow v$ alakú, ahol $A \in N$, $v \in (N \cup T)^*$.
- $i = 3$: P minden szabálya vagy $A \rightarrow uB$ vagy $A \rightarrow u$ alakú,
ahol $A, B \in N$ és $u \in T^*$.

Chomsky féle hierarchia

$$\mathcal{L}_3 \subseteq \mathcal{L}_2 \subseteq \mathcal{L}_1 \subseteq \mathcal{L}_0$$

Azonban

$$\mathcal{G}_3 \subseteq \mathcal{G}_2 \not\subseteq \mathcal{G}_1 \subseteq \mathcal{G}_0$$

Ha a 2-es típusú szabályoknál is kikötnénk, hogy $v \neq \varepsilon$, akkor igaz lenne a tartalmazás, és akkor triviálisan igaz lenne a nyelvcsaládokra is tartalmazás.

Nyelvtani transzformáció

A nyelvtani transzformáció olyan eljárás, amely egy G grammatikából egy másik G' grammatikát készít.

Ekvivalens transzformációról beszélünk, ha minden G grammatikára és az ő G' transzformáltjára igaz, hogy $L(G)=L(G')$.

ε -mentesítés

Tétel:

Minden $G=(N,T,P,S)$ környezetfüggetlen (2-es típusú) grammatikához megkonstruálható egy vele ekvivalens $G'=(N',T,P',S')$ környezetfüggetlen grammatika úgy, hogy P' -ben **nincs** $A \rightarrow \varepsilon$ alakú szabály, kivéve, ha $\varepsilon \in L(G)$, mert akkor $S' \rightarrow \varepsilon \in P'$, de ekkor S' nem szerepelhet szabály jobboldalán.

ϵ -mentesítés

Első lépésben meghatározzuk, hogy mely nemterminálisokból vezethető le az üres szó.

$$H := \{ A \in N \mid A \xRightarrow[G]{*} \epsilon \}$$

Ehhez definiáljuk a H_i ($i \geq 1$) halmazokat:

$$H_1 := \{ A \in N \mid \exists A \rightarrow \epsilon \in P \}$$

$$H_{i+1} := H_i \cup \{ A \in N \mid \exists A \rightarrow w \in P \text{ és } w \in H_i^* \}$$

$$H_1 \subseteq H_2 \subseteq \dots \subseteq H_k = H_{k+1} \exists k \text{ és legyen } H := H_k.$$

ε -mentesítés

Ekkor látható,
ha $A \in N$ és $A \xRightarrow[G]{*} \varepsilon$, akkor, és csak akkor, ha $A \in H$.

Ennek következménye, hogy
 $\varepsilon \in L(G)$, akkor, és csak akkor, ha $S \in H$.

ϵ -mentesítés

Második lépésben átalakítjuk H ismeretében a grammatika szabályait a kellő alakúra.

$S \notin H$ esetén:

$A \rightarrow v' \in P'$, akkor, és csak akkor, ha $v' \neq \epsilon$ és $\exists A \rightarrow v \in P$ úgy, hogy v' -t v -ből úgy kapjuk, hogy elhagyunk nulla vagy több H -beli nemterminálist v -ből.

ϵ -mentesítés

$S \in H$ estén:

A korábbi szabályokhoz hozzá vesszük még a következő két szabályt:

$$S' \rightarrow \epsilon \text{ és } S' \rightarrow S$$

,ahol $S' \notin N$ a G' grammatika új kezdőszimbóluma.

Megjegyzés: Az átalakítás megőrzi a 2. és 3. típust.

Példa

$$L = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \geq 0 \}$$

$$G = (\{S\}, \{a,b\}, P, S)$$

$$P: S \rightarrow aSbS$$

$$S \rightarrow bSaS$$

$$S \rightarrow \varepsilon$$

és $L(G) = L$. (Ezt korábban bizonyítottuk.)

Példa

$L = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \}$, azaz ugyanannyi „a” és „b” van a szavakban.

$G = (\{S\}, \{a,b\}, P, S)$

$G' = (\{S', S\}, \{a,b\}, P', S')$

$P: S \rightarrow aSbS$

$P': S \rightarrow aSbS$

$S \rightarrow abS$

$S \rightarrow aSb$

$S \rightarrow ab$

$S \rightarrow bSaS$

$S \rightarrow bSaS$

$S \rightarrow baS$

$S \rightarrow bSa$

$S \rightarrow ba$

$S \rightarrow \varepsilon$

$S' \rightarrow \varepsilon, S' \rightarrow S$

és $L(G) = L(G')$.

Példa

u=abba szó levezetése:

$$S \xRightarrow{G} aSbS \xRightarrow{G} aSbSaS \xRightarrow{G} abbSaS \xRightarrow{G} abbaS \xRightarrow{G} abba$$

$$S' \xRightarrow{G'} S \xRightarrow{G'} abS \xRightarrow{G'} abba$$

Példa

$G = (\{S, A, B\}, \{a, b\}, P, S)$

$P: S \rightarrow aAS$

$S \rightarrow AaB$

$S \rightarrow AB$

$A \rightarrow BB$

$B \rightarrow bA$

$B \rightarrow \varepsilon$

$H_1 = \{B\}$

$H_2 = H_1 \cup \{A\} = \{A, B\}$

$H_3 = H_2 \cup \{S\} = \{A, B, S\} = N$

$H = H_3$

$G' = (\{S', S, A, B\}, \{a, b\}, P', S')$

$P': S \rightarrow aAS \mid aS \mid aA \mid a$

$S \rightarrow AaB \mid aB \mid Aa \mid a$

$S \rightarrow AB \mid B \mid A$

$A \rightarrow BB \mid B$

$B \rightarrow bA \mid b$

$S' \rightarrow \varepsilon$

$S' \rightarrow S$

Köszönöm a figyelmet!