

Formális nyelvek és a fordítóprogramok alapjai

3. előadás

Előadó: Nagy Sára, mesteroktató
Algoritmusok és Alkalmazásaik Tanszék

Emlékeztető

Definíció: Grammatikának a következő négyest nevezzük:

$G=(N,T,P,S)$

- N a nemterminális ábácé,
- T a terminálisok ábécéje,
- P az átírási szabályok véges halmaza,
- S a kezdőszimbólum.

Emlékeztető

Nyelvtan által generált nyelv:

$$L(G) := \{ u \in T^* \mid S \xRightarrow[G]{*} u \}$$

Ekvivalens nyelvtanok:

A G_1 es G_2 nyelvtanok ekvivalensek, ha $L(G_1) = L(G_2)$.

Emlékeztető

Reguláris műveletek:

- **unió**
- **konkatenáció**
- **(iteratív) lezárás**

Nyelvosztályok zártsága a reguláris műveletekre

Tétel:

Az \mathcal{L}_i , $i = 0, 1, 2, 3$ nyelvosztályok mindegyike zárt a reguláris műveletekre nézve.

Nyelvosztály zártsága nyelvi műveletre

Legyen φ n -változós nyelvi művelet, azaz
ha L_1, \dots, L_n nyelvek, akkor $\varphi(L_1, \dots, L_n)$ is nyelv.

Az \mathcal{L} nyelvcsalád zárt a φ műveletre nézve,
ha $L_1, \dots, L_n \in \mathcal{L}$ estén $\varphi(L_1, \dots, L_n) \in \mathcal{L}$.

Unió

$G=(N,T,P,S)$ legyen az L nyelvhez tartozó grammatika és
 $G'=(N',T,P',S')$ legyen az L' nyelvhez tartozó grammatika és
 $N \cap N' = \emptyset$ és a korábbi normál formában adottak.

$i=0,2,3$ esetén, legyen S_0 új szimbólum, azaz $S_0 \notin (N \cup N')$.

$G_U = (N \cup N' \cup \{S_0\}, T, P \cup P' \cup \{S_0 \rightarrow S, S_0 \rightarrow S'\}, S_0)$.

Látható, hogy G_U típusa megegyezik G, G' típusával,
és $L(G) \cup L(G') = L(G_U)$

Unió

$i=1$ estén, ha $\varepsilon \in (L \cup L')$, akkor az előbbi módon elkészített grammatikában nem teljesül a KES.

Ezért tekintsük az $L_1 = L \setminus \{\varepsilon\}$ és $L_2 = L' \setminus \{\varepsilon\}$ nyelveket, amelyeket G_1 és G_2 1-es típusú grammatikák generálnak. Készítsük el G_U -t az előbbi módon, majd vezessünk be egy S_1 új kezdőszimbólumot és adjuk a szabályhalmazhoz az $S_1 \rightarrow \varepsilon$ és $S_1 \rightarrow S_0$ szabályokat.

Emlékeztető

$G=(N,T,P,S)$ grammatika **3-as típusú**, ha szabályai

$A \rightarrow uB$ alakúak, ahol $A,B \in N$, $u \in T^*$ vagy

$A \rightarrow u$ alakúak, ahol $A \in N$, $u \in T^*$

Konkatenáció

(Megjegyzés: Most csak a 3-as típusra bizonyítjuk.)

Legyen $i = 3$.

A P szabályhalmazból megkonstruálunk egy P_1 szabályhalmazt úgy, hogy minden

$A \rightarrow u$ alakú szabályt felcserélünk egy $A \rightarrow uS'$ alakú szabályra, a többi szabályt változatlanul hagyjuk.

A $G_c = (N \cup N', T, P_1 \cup P', S)$ grammatika 3-as típusú és generálja az $L(G)L(G')$ nyelvet.

Lezárás

(Megjegyzés: Most csak a 3-as típusra bizonyítjuk.)

Legyen $i = 3$.

Definiáljuk a P_1 szabályhalmazt úgy, hogy minden $A \rightarrow u$ alakú szabályt felcserélünk egy $A \rightarrow uS$ alakú szabályra és ezek legyenek a P_1 elemei.

Legyen S_0 új szimbólum, azaz $S_0 \notin N$.

$G_* = (N \cup \{S_0\}, T, P_1 \cup P \cup \{S_0 \rightarrow \varepsilon, S_0 \rightarrow S\}, S_0)$

grammatika generálja az L^* nyelvet.

3-típusú grammatikák normál formája

Tétel:

Minden 3-as típusú, nyelv generálható egy olyan grammatikával, amelynek szabályai

$A \rightarrow aB$, ahol $A, B \in N$ és $a \in T$ vagy

$A \rightarrow \varepsilon$ alakúak, ahol $A \in N$.

Megjegyzés: A 3-as normál forma alakítható majd át könnyen automatává.

3-as típusú grammatikák normálformára hozása

Legyen $G=(N,T,P,S)$ 3-as típusú grammatika.

Megkonstruálunk egy $G'=(N',T,P',S)$ 3-as normál formájú grammatika, melyre $L(G)=L(G')$.

Lépesei:

1. hosszredukció
2. befejező szabályok átalakítása
3. láncmentesítés

Hosszredukció

Elhagyjuk az $A \rightarrow a_1 \dots a_k B$ alakú szabályokat,
ahol $k \geq 2$ és $\forall i \in [1, k]: a_i \in T$ és $A \in N$, $B \in N$ vagy $B = \epsilon$.

Helyettesítjük a következő szabályokkal:

$A \rightarrow a_1 Z_1$, ahol $Z_1 \notin N$, azaz új nemterminális,

$Z_1 \rightarrow a_2 Z_2$, ahol $Z_2 \notin (N \cup Z_1)$

...

$Z_{k-1} \rightarrow a_k B$

Megjegyzés: Minden szabályra új nemterminálisokat vezetünk be.

Befejező szabályok átalakítása

Elhagyjuk az $A \rightarrow a$ alakú szabályokat, ahol $a \in T$ és $A \in N$.

Legyen E egy új nemterminális.
(Ez lehet közös minden befejező szabály esetén.)

Vegyük fel P' -be az

$A \rightarrow aE$ és a $E \rightarrow \epsilon$ szabályokat az előbbiek helyett.

Megjegyzés: A 3-as normál forma alakítható majd át könnyen automatává.

Láncmentesítés

Elhagyjuk az $A \rightarrow B$ alakú szabályokat P -ből, ahol $A, B \in N$.

Első lépésben meghatározzuk minden $A \in N$ esetén a

$H(A) := \{ B \in N \mid A \xRightarrow[G]{*} B \}$ halmazokat.

Ehhez definiáljuk a H_i ($i \geq 1$) halmazokat:

$H_1(A) = \{ A \}$

$H_{i+1}(A) = H_i(A) \cup \{ B \in N \mid \exists C \in H_i(A) \text{ és } C \rightarrow B \in P \}$

$H_1(A) \subseteq H_2(A) \subseteq \dots \subseteq H_k(A) = H_{k+1}(A) \exists k$ és legyen $H(A) := H_k(A)$.

Ezután P' -be felvesszük az $A \rightarrow X$ szabályokat,

ha $\exists B \in H(A)$ és $B \rightarrow X \in P$, ahol $X \in (T \cup N)^*$ és X nem csak egyetlen nemterminális.

Példa

P: $S \rightarrow abS$

$S \rightarrow B$

$B \rightarrow bB$

$B \rightarrow V$

$V \rightarrow aa$

hosszredukció után:

P': $S \rightarrow aZ$

$Z \rightarrow bS$

$S \rightarrow B$

$B \rightarrow bB$

$B \rightarrow V$

$V \rightarrow aY$

$Y \rightarrow aE$

$E \rightarrow \varepsilon$

Példa

$P': S \rightarrow aZ$

$Z \rightarrow bS$

$S \rightarrow B$

$B \rightarrow bB$

$B \rightarrow V$

$V \rightarrow aY$

$Y \rightarrow aE$

$E \rightarrow \varepsilon$

$H(S) = \{S, B, V\}$

$H(B) = \{B, V\}$

$H(V) = \{V\}$

láncmentesítés után:

$P': S \rightarrow aZ$

$Z \rightarrow bS$

$S \rightarrow bB \mid aY$

$B \rightarrow bB$

$B \rightarrow aY$

$V \rightarrow aY$

$Y \rightarrow aE$

$E \rightarrow \varepsilon$

Emlékeztető

Reguláris műveletek:

- ▶ unió, $(L_1 \cup L_2)$
- ▶ konkatenáció, $(L_1 L_2)$
- ▶ (iteratív) lezárás. $(L^* = L^0 \cup L^1 \cup L^2 \cup \dots)$

3-as nyelvcsalád leírásai

A 3-as nyelvcsalád nyelveit leírhatjuk

- 3-as típusú grammatikával,
- reguláris kifejezéssel,
- véges determinisztikus automatával,
- véges nemdeterminisztikus automatával.

Bizonyítható, hogy

$$\mathcal{L}_3 = \mathcal{L}_{\text{reg}} = \mathcal{L}_{\text{VDA}} = \mathcal{L}_{\text{VNDA}} \cdot$$

Megjegyzés: A programozási nyelvek lexikális egységei a 3-as nyelvcsaládba tartoznak.

Reguláris nyelvek (rekurzív definíció)

- az elemi nyelvek: \emptyset , $\{\varepsilon\}$, $\{a\}$, ahol $a \in U$, azaz egy tetszőleges betű
- azon nyelvek, melyek az elemi nyelvekből az unió, a konkatenáció és a lezárás műveletek véges számú alkalmazásával állnak elő;
- nincs más reguláris nyelv

Példa: $\{\{a\} \cup \{b\}\}^*\{b\} = \{ub \mid u \in \{a,b\}^*\}$

Reguláris nyelvek

Tétel: Minden L reguláris nyelvhez megadható egy G 3-as típusú grammatika, amelyre $L=L(G)$. ($\mathcal{L}_{\text{reg}} \subseteq \mathcal{L}_3$)

Bizonyítás:

Elemi nyelvekhez adható 3-as típusú grammatika.

$G=(\{S\},\{a\},\{S\rightarrow aS\},S)$ $L(G)=\emptyset$

$G=(\{S\},\{a\},\{S\rightarrow \varepsilon\},S)$ $L(G)=\{\varepsilon\}$

$G=(\{S\},\{a\},\{S\rightarrow a\},S)$ $L(G)=\{a\}$

Bizonyítás folytatása

Korábban láttuk, hogy az \mathcal{L}_3 nyelvcsalád zárt a reguláris műveletekre nézve.

Az elemi nyelvek grammatikáiból kiindulva megkonstruálható a reguláris műveletekhez tartozó grammatika konstrukciókkal a megfelelő 3-as típusú grammatika bármely összetett reguláris nyelvhez.

Reguláris kifejezések:

Definíció:

- az elemi regularis kifejezések: \emptyset , ε , a , ahol $a \in U$
- ha R_1 és R_2 és R regularis kifejezések akkor
$$(R_1 \mid R_2);$$
$$(R_1 R_2);$$
$$(R)^*$$
 is reguláris kifejezések.
- a reguláris kifejezések halmaza a legszűkebb halmaz, melyre a fenti két pont teljesül.

Reguláris kifejezések:

Jelölje L_R az R reguláris kifejezéshez tartozó nyelvet.

$$L_{\emptyset} = \emptyset, L_{\varepsilon} = \{\varepsilon\}, L_a = \{a\}$$

Ha Q és R reguláris kifejezések, akkor

$$L_{(Q|R)} = L_Q \cup L_R$$

unió

$$L_{(QR)} = L_Q L_R$$

konkatenáció

$$L_{(R)^*} = (L_R)^*$$

lezárás

Reguláris kifejezések:

A műveletek prioritási sorrendje növekvően:
unió, konkatenáció, lezárás.

A zárójelek elhagyhatók a reguláris kifejezésekből a prioritásoknak megfelelően.

Példák reguláris kifejezésekre

- $(a|b)^*b$, ahol
 $L_{(a|b)^*b} = \{\{a\} \cup \{b\}\}^*\{b\} = \{ub \mid u \in \{a,b\}^*\}$
- $L_{aa^*b^*} = \{a, aa, ab, aaa, aab, abb, \dots\}$
 $aba \notin L_{aa^*b^*}$

Példák reguláris kifejezésekre

$0|1(0|1)^*0$ $T=\{0,1\}$

A fenti reguláris kifejezésnek a páros bináris számoknak felelnek meg, vezető nullák nélkül.

Érdekes helyek, ahol gyakorolhatók a reguláris kifejezések.

<https://regexone.com/>

<https://regexcrossword.com/>

Megjegyzés: A megadott kifejezések a Flex programgenerátor kifejezéseinek részét képezik.

Véges determinisztikus automata (VDA)

Definíció:

$A = (Q, T, \delta, q_0, F)$ rendezett ötöst véges determinisztikus automatának nevezzük, ahol

- Q az állapotok nem üres véges halmaza,
- T az input szimbólumok ábécéje,
- $\delta: Q \times T \rightarrow Q$ leképezés az állapot-átmeneti függvény,
- $q_0 \in Q$ a kezdőállapot,
- $F \subseteq Q$ elfogadóállapotok halmaza.

Véges determinisztikus automata (VDA)

Véges determinisztikus automata esetén a

$\delta: Q \times T \rightarrow Q$ állapot-átmeneti függvény

$\forall (q,a)$ párra értelmezett, ahol

$(q,a) \in Q \times T$ és egyetlen olyan $p \in Q$ állapot van, amelyre $\delta(q,a) = p$.

Példa

Legyen $A = (Q, T, \delta, q_0, F)$ a következő, ahol

$Q = \{q_0, q_1, q_2, q_3\}$, $T = \{a, b\}$, $F = \{q_0\}$ és

$\delta(q_0, a) = q_2$, $\delta(q_0, b) = q_1$,

$\delta(q_1, a) = q_3$, $\delta(q_1, b) = q_0$,

$\delta(q_2, a) = q_0$, $\delta(q_2, b) = q_3$,


$\delta(q_3, a) = q_1$, $\delta(q_3, b) = q_2$.

$L(A) = \{u \in T^* \mid u\text{-ban páros sok } 'a' \text{ betű és páros sok } 'b' \text{ betű van}\}$

Példa - automata megadása táblázattal

δ	a	b
$\begin{array}{c} \rightarrow \\ \leftarrow \end{array} q_0$	q_2	q_1
q_1	q_3	q_0
q_2	q_0	q_3
q_3	q_1	q_2

Példa - automata megadása gráffal



δ	a	b
\Rightarrow q0	q2	q1
q1	q3	q0
q2	q0	q3
q3	q1	q2

Automata működése

δ	a	b
q0	q2	q1
q1	q3	q0
q2	q0	q3
q3	q1	q2

a	b	b	a	b	b		
---	---	---	---	---	---	--	--




aktuális
állapot: q0

Automata működése

δ	a	b
q0	q2	q1
q1	q3	q0
q2	q0	q3
q3	q1	q2


a	b	b	a	b	b		
---	---	---	---	---	---	--	--



Automata működése


δ	a	b
q0	q2	q1
q1	q3	q0
q2	q0	q3
q3	q1	q2

a	b	b	a	b	b		
---	---	---	---	---	---	--	--



Automata működése

δ	a	b
q0	q2	q1
q1	q3	q0
q2	q0	q3
q3	q1	q2



Automata működése

δ	a	b
q0	q2	q1
q1	q3	q0
q2	q0	q3
q3	q1	q2

a	b	b	a	b	b		
---	---	---	---	---	---	--	--

aktuális
állapot: q0



Automata működése

δ	a	b
q0	q2	q1
q1	q3	q0
q2	q0	q3
q3	q1	q2



aktuális
állapot: q1



Automata működése

δ	a	b
\Rightarrow \Leftarrow q0	q2	q1
q1	q3	q0
q2	q0	q3
q3	q1	q2



aktuális
állapot: q0

q0 elfogadó
állapot, tehát a
szó jó

Alternatív jelölés az állapot-átmenetre

$\delta(q, a) = p$ állapot átmenetet jelölhetjük egy
 $qa \rightarrow p$ szabállyal.

Ha minden egyes (q, a) párra egyetlen $qa \rightarrow p$ szabály van, akkor a véges automata determinisztikus, egyébként nemdeterminisztikus.

Közvetlen redukció

Legyen $A = (Q, T, \delta, q_0, F)$ egy véges determinisztikus automata és legyenek $u, v \in QT^*$.

(Konfiguráció: aktuális állapot, input hátralévő része.)

Azt mondjuk, hogy az A automata az u konfigurációt a v konfigurációra redukálja közvetlenül (jelölés: $u \Rightarrow_A v$), ha van olyan

$qa \rightarrow p$ szabály (azaz $\delta(q, a) = p$) és van olyan $w \in T^*$ szó, amelyre

$u = qaw$ és $v = pw$ teljesül.

Redukció

Definíció:

Az $A = (Q, T, \delta, q_0, F)$ véges automata az $u \in QT^*$ konfigurációt a $v \in QT^*$ konfigurációra redukálja (jelölés: $u \Rightarrow_A^* v$), ha vagy $u = v$, vagy van olyan $z \in QT^*$, amelyre $u \Rightarrow_A^* z$ és $z \Rightarrow_A v$ teljesül.

Automata által elfogadott nyelv

Definíció:

Az $A = (Q, T, \delta, q_0, F)$ véges automata által elfogadott nyelv alatt az

$$L(A) := \{u \in T^* \mid \exists q_0 u \xRightarrow[A]{*} p \text{ és } p \in F\}$$

szavak halmazát értjük.

Megjegyzés: Ez azt jelenti, hogy van olyan működése az automatának, hogy a kezdőállapotból indulva végig olvasva az inputot elfogadóállapotba jut.

Köszönöm a figyelmet!