

Formális nyelvek és a fordítóprogramok alapjai

6. előadás

Előadó: Nagy Sára, mesteroktató
Algoritmusok és Alkalmazásaik Tanszék

Emlékeztető

Chomsky féle hierarchia:

$$\mathcal{L}_3 \subset \mathcal{L}_2 \subset \mathcal{L}_1 \subset \mathcal{L}_0$$

$G=(N,T,P,S)$ grammatika 2-es típusú, ha szabályai

$A \rightarrow u$ alakúak, ahol $A \in N$, $u \in (N \cup T)^*$

Ezeket nevezzük *környezetfüggetlen* grammatikáknak. Ilyenekkel írható le a programozási nyelvek szintaxisa.

2-típusú grammatikák normálformája

Definíció:

Egy $G=(N,T,P,S)$ környezetfüggetlen grammatikát **Chomsky-normálformájúnak** mondunk, ha szabályai

- $A \rightarrow a$, ahol $A \in N$ és $a \in T$ vagy
- $A \rightarrow BC$ alakúak, ahol $A,B,C \in N$.
- $S \rightarrow \varepsilon$, de ekkor S nem fordul elő egyetlen szabály jobboldalán sem.

Megjegyzés: A 2-es típusú grammatikák Chomskynormálformára hozásának algoritmus a nem a tananyag része.

Bar-Hillel lemma (pumpáló lemma)

Minden L környezetfüggetlen nyelvhez megadható két nyelvtől függő természetes szám p és q úgy, hogy

$\forall u \in L$ szóra, ha $\ell(u) > p$, akkor u felírható

$$u = vxwyz$$

alakban, ahol $v, x, w, y, z \in T^*$ és

- $\ell(xwy) \leq q$,
- $xy \neq \varepsilon$,
- $vx^iwy^iz \in L, \forall i \geq 0$ esetén.

Megjegyzés: A lemmát nem bizonyítjuk, de a bizonyításhoz szükséges, hogy a 2-es típusú nyelvekhez léteznek Chomsky-normálformájú grammatika.

Következmény

Van olyan nyelv, amely nem környezetfüggetlen.

Például $L = \{ a^n b^n c^n \mid n > 0 \} \notin \mathcal{L}_2$.

Tegyük fel indirekt, hogy $\exists p, q$ a Bar-Hillel lemmának megfelelő konstansok.

Legyen $k > p$ és $k > q$ is. Ekkor $u = a^k b^k c^k > p$.

A lemma szerint az u szó $vwyz$ alakban felbontható kell legyen, úgy, hogy $\ell(xwy) \leq q < k$ és x és y párhuzamosan beiterálható.

De ekkor xy -ban nem lehet mindhárom betűből, így vwz nem lehet eleme L -nek, ami ellentmondás.

Szóprobléma eldöntése

Tétel:

Minden $G=(N,T,P,S)$ környezetfüggetlen grammatika esetében eldönthető, hogy egytetszőleges $u \in T^*$ szó benne van-e a G grammatika által generált nyelvben vagy sem.

Másképpen $u \in L(G)$ igaz-e?

Szóprobléma eldöntése

Bizonyítás:

Az általánosság megszorítása nélkül feltehetjük, hogy G Chomsky normálformában van.

Az, hogy az üres szó benne van-e nyelvben az attól függ, hogy van-e $S \rightarrow \varepsilon$ szabály G -ben.

Ha u nem az üres szó, akkor $k = 2^{\ell(u)} - 1$ lépésben levezethető kell legyen G -ben.

Mivel a k lépésben levezethető szavak halmaza véges, ezért eldönthető, hogy u benne van-e ebben a halmazban.

Veremautomata

Definíció:

$A = (\mathbf{Z}, Q, T, \delta, \mathbf{z_0}, q_0, F)$ rendezett hetest veremautomatának nevezzük, ahol

- Z a verem szimbólumok ábécéje,
- Q az állapotok nem üres véges halmaza,
- T az input szimbólumok ábécéje,
- $\delta: \mathbf{Z} \times \mathbf{Q} \times (T \cup \{\varepsilon\}) \rightarrow 2^{Z^* \times Q}$ leképezés az állapot-átmeneti függvény, ahol δ véges részhalmazokba képez,
- $z_0 \in Z$ a kezdő veremszimbólum,
- $q_0 \in Q$ a kezdőállapot,
- $F \subseteq Q$ elfogadó állapotok halmaza.

Veremautomata állapot-átmenete

Egy lépésben mindig kell egy jelet olvasni a verem tetejéről és csak egy jelet lehet elérni. Az input szalagról is egy jelet lehet olvasni, de nem kötelező.

Megváltoztatható az automata aktuális állapota, illetve a verem teteje. Egy lépésben egy egész sorozatot is beírhatunk a verembe.

Példák:

► $\delta(\#, q_0, a) = \{(\#a, q_0)\}$

Jelentése: Ha $\#$ van a verem tetején és a betű jön az inputon, akkor tegyük be a -t a verembe.

► $\delta(\#, q_0, a) = \{(\epsilon, q_0)\}$

Jelentése: Ha $\#$ van a verem tetején és a betű jön az inputon, akkor töröljük $\#$ -t a veremből.

► $\delta(\#, q_0, a) = \{(\#, q_0)\}$

Jelentése: Ha $\#$ van a verem tetején és a betű jön az inputon, akkor ne változtassuk a verem tartalmát.

► $\delta(\#, q_0, \epsilon) = \{(\#bb, q_0)\}$

Jelentése: Ha $\#$ van a verem tetején és nem olvasunk az inputról, akkor tegyünk a verembe két b betűt.

Példa

Legyen $L = \{a^n b^n \mid n \geq 1\}$.

Ezt a nyelvet felismerő veremautomata:

$A = (\{ \#, a \}, \{ q_0, q_1, q_2 \}, \{ a, b \}, \delta, \#, q_0, \{ q_2 \})$

$$\delta(\#, q_0, a) = \{(\#a, q_0)\}$$

$$\delta(a, q_0, a) = \{(aa, q_0)\}$$


$$\delta(a, q_0, b) = \{(\varepsilon, q_1)\}$$

$$\delta(a, q_1, b) = \{(\varepsilon, q_1)\}$$

$$\delta(\#, q_1, \varepsilon) = \{(\#, q_2)\}$$

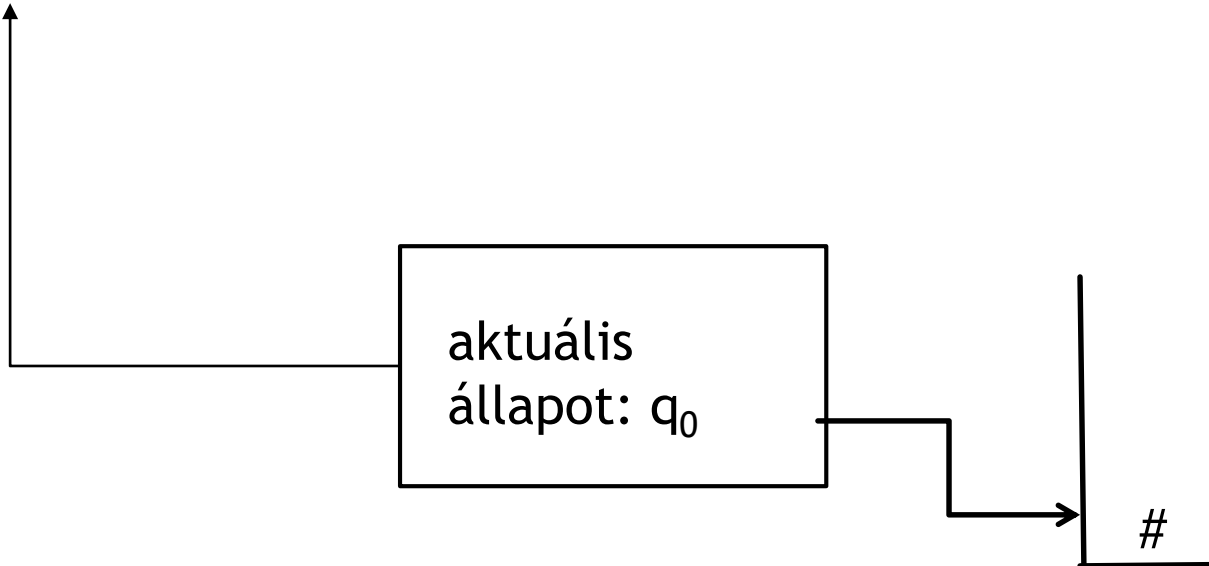

Megjegyzés: Itt most csak egy eleműek a halmazok. Gyakran ilyenkor nem írjuk ki a halmaz jelet.

Példa - veremautomata gráf



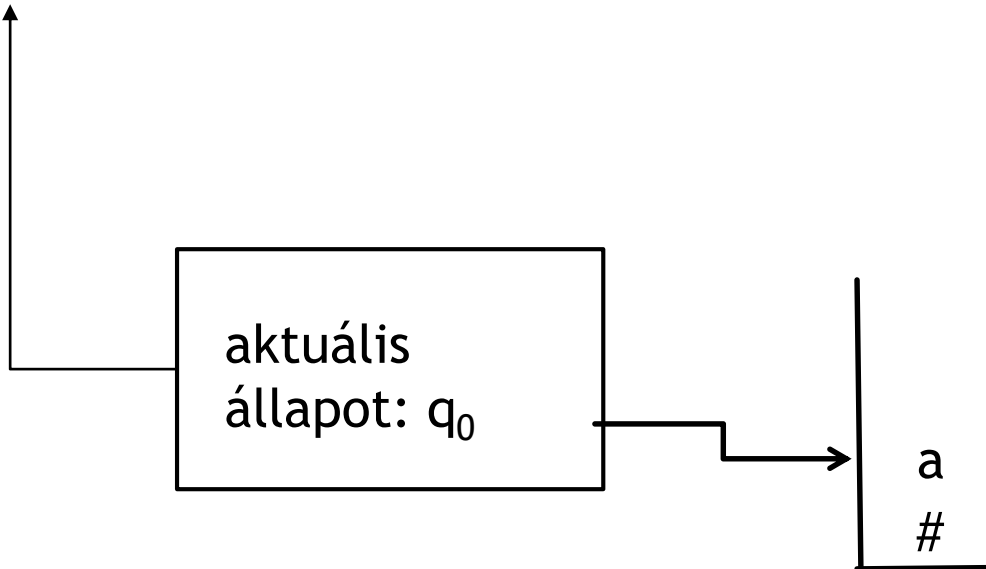

$\delta(\#, q_0, a) = (\#a, q_0)$
 $\delta(a, q_0, a) = (aa, q_0)$
 $\delta(a, q_0, b) = (\epsilon, q_1)$
 $\delta(a, q_1, b) = (\epsilon, q_1)$
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$

Veremautomata működése



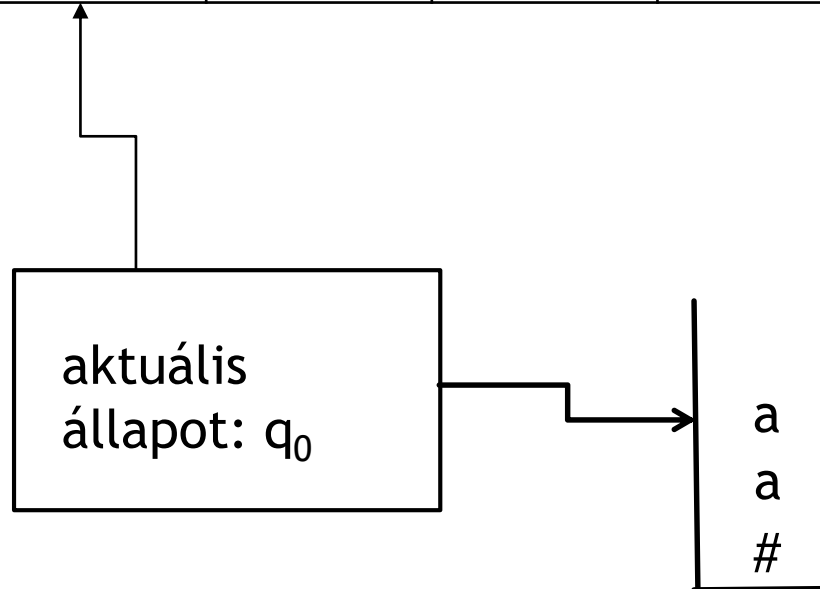

$\delta(\#, q_0, a) = (\#a, q_0)$
 $\delta(a, q_0, a) = (aa, q_0)$
 $\delta(a, q_0, b) = (\epsilon, q_1)$
 $\delta(a, q_1, b) = (\epsilon, q_1)$
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$

Veremautomata működése



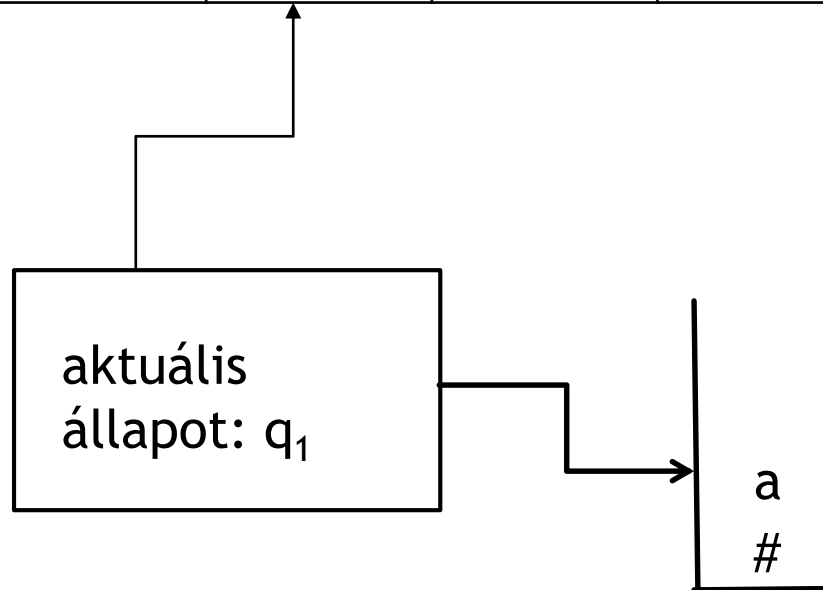

$\delta(\#, q_0, a) = (\#a, q_0)$
 $\delta(a, q_0, a) = (aa, q_0)$
 $\delta(a, q_0, b) = (\epsilon, q_1)$
 $\delta(a, q_1, b) = (\epsilon, q_1)$
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$

Veremautomata működése




$\delta(\#, q_0, a) = (\#a, q_0)$
 $\delta(a, q_0, a) = (aa, q_0)$
 $\delta(a, q_0, b) = (\epsilon, q_1)$
 $\delta(a, q_1, b) = (\epsilon, q_1)$
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$

Veremautomata működése





$\delta(\#, q_0, a) = (\#a, q_0)$
 $\delta(a, q_0, a) = (aa, q_0)$
 $\delta(a, q_0, b) = (\epsilon, q_1)$
 $\delta(a, q_1, b) = (\epsilon, q_1)$
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$

Veremautomata működése



$\delta(\#, q_0, a) = (\#a, q_0)$
 $\delta(a, q_0, a) = (aa, q_0)$
 $\delta(a, q_0, b) = (\epsilon, q_1)$
 $\delta(a, q_1, b) = (\epsilon, q_1)$
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$

Veremautomata működése



$\delta(\#, q_0, a) = (\#a, q_0)$
 $\delta(a, q_0, a) = (aa, q_0)$
 $\delta(a, q_0, b) = (\epsilon, q_1)$
 $\delta(a, q_1, b) = (\epsilon, q_1)$
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$

Az aktuális állapot elfogadó
és a szót végig olvastuk.
Tehát jó a szó.

Veremautomata - alternatív jelöléssel

Ha $\delta(z, q, a) = \{(w_1, r_1), \dots, (w_k, r_k)\}$, akkor ezt a leképezést a következő szabályhalmazzal is jelölhetjük:

$$\mathbf{zqa} \rightarrow \mathbf{w_i r_i} , \text{ ahol } 1 \leq i \leq k.$$

Ha $\delta(z, q, \varepsilon) = \{(w_1, r_1), \dots, (w_k, r_k)\}$, akkor ezt a leképezést a következő szabályhalmazzal is jelölhetjük:

$$\mathbf{zq} \rightarrow \mathbf{w_i r_i} , \text{ ahol } 1 \leq i \leq k.$$

Tehát a szabályok baloldala **ZQT** vagy **ZQ** alakú és a jobboldala **Z*Q** alakú.

Veremautomata - alternatív jelöléssel

Példa:

Legyen $L = \{a^n b^n \mid n \geq 1\}$.

Ezt a nyelvet felismerő veremautomata:

$A = (\{ \#, a \}, \{ q_0, q_1, q_2 \}, \{ a, b \}, \delta, \#, q_0, \{ q_2 \})$

$\#q_0a \rightarrow \#aq_0$

$aq_0a \rightarrow aaq_0$

$aq_0b \rightarrow q_1$

$aq_1b \rightarrow q_1$

$\#q_1 \rightarrow \#q_2$

Konfiguráció

Legyen $A = (Z, Q, T, \delta, z_0, q_0, F)$ egy veremautomata és legyen $\alpha \in Z^*QT^*$.

Azt mondjuk α az A veremautomata egy **konfigurációja**.

A konfiguráció a veremautomata egy pillanatnyi állapotát írja le.

Ha $\alpha = zqu$, ahol $z \in Z^*$ és $q \in Q$ és $u \in T^*$ és

$z = z_1 \dots z_k$ és $u = u_1 \dots u_m$, akkor z_1 a verem alján és z_k a tetején lévő karakter és u az input szöveg még el nem olvasott része, ahol u_1 a soron következő karakter.

Kezdő konfiguráció: z_0q_0w , ahol $w \in T^*$ az elemzendő szó.

Közvetlen redukció - definíció

Legyen $A = (Z, Q, T, \delta, z_0, q_0, F)$ egy veremautomata és legyenek $\alpha, \beta \in Z^*QT^*$ konfigurációk.

(Konfiguráció: verem, aktuális állapot, input hátralévő része.)

Azt mondjuk, hogy az A veremautomata az α konfigurációt a β konfigurációra **redukálja** közvetlenül (jelölés: $\alpha \xRightarrow{A} \beta$),

ha van olyan $z \in Z$, $q, p \in Q$, $a \in T \cup \{\varepsilon\}$ és $r, u \in Z^*$, $w \in T^*$ szó, hogy $zqa \rightarrow up$ egy szabály és

$\alpha = r\mathbf{zq}aw$ és $\beta = r\mathbf{up}w$ teljesül.

Redukció - definíció

Legyen $A = (Z, Q, T, \delta, z_0, q_0, F)$ egy veremautomata és legyenek $\alpha, \beta \in Z^*QT^*$.

(Konfiguráció: verem, aktuális állapot, input hátralévő része.)

Azt mondjuk, hogy az A veremautomata az α konfigurációt a β konfigurációra redukálja (jelölés: $\alpha \Rightarrow_A^* \beta$),

ha vagy $\alpha = \beta$ vagy létezik $\alpha_1, \dots, \alpha_k$ konfiguráció sorozat, hogy $\alpha_1 = \alpha$ és $\alpha_k = \beta$ és $\alpha_i \Rightarrow_A \alpha_{i+1}$ $1 \leq i \leq k-1$.

Szó levezetése:

Legyen $L = \{a^n b^n \mid n \geq 1\}$.

Ezt a nyelvet felismerő veremautomata:

$A = (\{ \#, a \}, \{ q_0, q_1, q_2 \}, \{ a, b \}, \delta, \#, q_0, \{ q_2 \})$

$\#q_0a \rightarrow \#aq_0$

$aq_0a \rightarrow aaq_0$

$aq_0b \rightarrow q_1$

$aq_1b \rightarrow q_1$

$\#q_1 \rightarrow \#q_2$

$u = aabb$

$\#q_0aabb \xRightarrow{A} \#aq_0abb \xRightarrow{A} \#aaq_0bb \xRightarrow{A} \#aq_1b \xRightarrow{A} \#q_1 \xRightarrow{A} \#q_2$

Veremautomata által elfogadott nyelv

Elfogadó állapottal felismerhető nyelv:

$$L(A) := \{ u \in T^* \mid \exists z_0 q_0 u \xRightarrow[A]{*} wr \text{ és } r \in F \text{ és } w \in Z^* \}.$$

Megjegyzés: Ez azt jelenti, hogy van olyan működése a veremautomatának, hogy kezdő konfigurációból indulva végig olvasva az inputot elfogadóállapotba jut.

Üres veremmel felismerhető nyelv:

$$N(A) := \{ u \in T^* \mid \exists z_0 q_0 u \xRightarrow[A]{*} r \text{ és } r \in Q \}.$$

Megjegyzés: Ez azt jelenti, hogy van olyan működése a veremautomatának, hogy kezdő konfigurációból indulva végig olvasva az inputot teljesen kiüríti a vermet.

Determinisztikus veremautomata

Egy veremautomatát **determinisztikusnak** mondunk, ha minden $\alpha \in Z^+QT^*$ konfiguráció esetén egyetlen konfiguráció vezethető le közvetlenül α -ból.

Megjegyzés: Ez azt jelenti, hogy nincs két olyan szabály, amelynek azonos a baloldala, valamint, ha zq egy baloldal, akkor nincs zqa baloldal egyetlen terminálisra sem.

Determinisztikus és nemdeterminisztikus veremautomaták kapcsolata

A determinisztikus veremautomatával felismerhető nyelvek családja szűkebb, mint a nemdeterminisztikussal felismerhető nyelvek családja.

Például a szimmetrikus szavak nem ismerhetők fel determinisztikus veremautomatával.

Szimmetrikus szavakat felismerő veremautomata - alternatív jelöléssel

Példa: Legyen $L = \{uu^{-1} \mid u \in \{a,b\}^+\}$.

Ezt a nyelvet felismerő veremautomata:

$A = (\{\#, a, b\}, \{q_0, q_1, q_2\}, \{a, b\}, \delta, \#, q_0, \{q_2\})$

$\#q_0a \rightarrow \#aq_0$

$\#q_0b \rightarrow \#bq_0$

$aq_0a \rightarrow aaq_0$

$bq_0b \rightarrow bbq_0$

$aq_0b \rightarrow abq_0$

$bq_0a \rightarrow baq_0$

$aq_0a \rightarrow q_1$

$bq_0b \rightarrow q_1$

$aq_1a \rightarrow q_1$

$bq_1b \rightarrow q_1$

$\#q_1 \rightarrow q_2$

Szó levezetése:

$\#q_0a \rightarrow \#aq_0$	$\#q_0b \rightarrow \#bq_0$
$aq_0a \rightarrow aaq_0$	$bq_0b \rightarrow bbq_0$
$aq_0b \rightarrow abq_0$	$bq_0a \rightarrow baq_0$
$aq_0a \rightarrow q_1$	$bq_0b \rightarrow q_1$
$aq_1a \rightarrow q_1$	$bq_1b \rightarrow q_1$
$\#q_1 \rightarrow q_2$	

$u = abba$

$\#q_0abba \xRightarrow{A} \#aq_0bba \xRightarrow{A} \#abq_0ba \xRightarrow{A} \#abbq_0a \xRightarrow{A} \#abbaq_0 // \text{ nem jó}$

$\#q_0abba \xRightarrow{A} \#aq_0bba \xRightarrow{A} \#abq_0ba \xRightarrow{A} \#aq_1a \xRightarrow{A} \#q_1 \xRightarrow{A} q_2 // \text{ jó a szó}$

A kétféle elfogadás kapcsolata.

Lemma1:

Bármely A veremautomatához megadható A' veremautomata úgy, hogy $N(A')=L(A)$.

Lemma2:

Bármely A veremautomatához megadható A' veremautomata úgy, hogy $L(A')=N(A)$.

Megjegyzés: Ez azt jelenti, hogy ha egy nyelvhez építhető elfogadó állapottal felismerő veremautomata, akkor építhető üresveremmel felismerő veremautomata és fordítva.

A 2-es nyelvcsalád és a veremautomaták kapcsolata

Tétel:

Ha $L \in \mathcal{L}_2$, akkor megadható egy A veremautomata úgy, hogy $L=N(A)$, azaz $\mathcal{L}_2 \subseteq \mathcal{L}_{1v}$.

A 2-es nyelvcsalád és a veremautomaták kapcsolata

Bizonyítás:

Legyen $G=(N,T,P,S)$ egy környezetfüggetlen (2-es típusú) grammatika, amelyre $L=L(G)$.

Ekkor $A=(T \cup N, \{q_0\}, T, \delta, S, q_0, \emptyset)$, ahol δ a következő:

- $Xq_0 \rightarrow w^{-1}q_0$ akkor és csak akkor, ha $X \rightarrow w \in P$, $X \in N$, $w \in (T \cup N)^*$;
- $aq_0a \rightarrow q_0$ akkor és csak akkor, ha $a \in T$.

Megjegyzés: A egy egyállapotú üresveremmel elfogadó automata.

A 2-es nyelvcsalád és a veremautomaták kapcsolata

Bizonyítás folytatása:

A verem segítségével egy az elemzendő szó egy legbal levezetését szimuláljuk.

Ha nemterminális van a verem tetején, akkor valamelyik rá vonatkozó szabály jobboldalára cseréljük.

Ha terminális van a verem tetején, akkor az aktuális inputtal egyeztetjük, ha azonosak, akkor kivesszük a terminálist a veremből és tovább lépünk az inputban.

Példa

Legyen $L = \{a^n b^n \mid n \geq 1\}$ és $L = L(G)$, ahol

$$G = (\{S\}, \{a, b\}, P, S)$$

$$P: S \rightarrow aSb$$

$$S \rightarrow ab$$

Ezt a nyelvet felismerő veremautomata:

$$A = (\{S\}, \{q_0\}, \{a, b\}, \delta, S, q)$$

$$Sq_0 \rightarrow bSa q_0$$

$$Sq_0 \rightarrow ba$$

$$aq_0a \rightarrow q_0$$

$$bq_0b \rightarrow q_0$$

Példa

u = aabb szó elemzése:

$$Sq_0 \rightarrow bSa q_0$$

$$Sq_0 \rightarrow ba$$

$$aq_0a \rightarrow q_0$$

$$bq_0b \rightarrow q_0$$

$$\textcolor{blue}{S}q_0aabb \xRightarrow{\text{A}} b\textcolor{blue}{S}a\textcolor{blue}{q}_0aabb \xRightarrow{\text{A}} b\textcolor{blue}{S}q_0abb \xRightarrow{\text{A}} bb\textcolor{blue}{a}q_0abb \xRightarrow{\text{A}}$$

$$\xRightarrow{\text{A}} bb\textcolor{blue}{q}_0bb \xRightarrow{\text{A}} b\textcolor{blue}{q}_0b \xRightarrow{\text{A}} q_0, \text{ azaz } u \text{ jó szó.}$$

Példa

u = aabb szó elemzése:

konfiguráció: verem, aktuális állapot, input (Z^*QT^*)

inicializálás:

Sq_0aabb



$bSa q_0aabb$



bSq_0abb


$Sq_0 \rightarrow bSa q_0$

$Sq_0 \rightarrow ba$

$aq_0a \rightarrow q_0$

$bq_0b \rightarrow q_0$

szintaxis fa



Példa

u = aabb szó elemzése:

Z^*QT^*

Sq_0aabb
 bSq_0aabb
 bSq_0abb
 \downarrow
 $bbaq_0abb$
 bbq_0bb
 bq_0b
 q_0


$Sq_0 \rightarrow bSq_0$

$Sq_0 \rightarrow ba$

$aq_0a \rightarrow q_0$

$bq_0b \rightarrow q_0$

szintaxis fa



A 2-es nyelvcsalád és a veremautomaták kapcsolata

Tétel:

Minden A veremautomatához megadható egy környezetfüggetlen G grammatika úgy, hogy $L(G)=N(A)$, azaz $\mathcal{L}_{1v} \subseteq \mathcal{L}_2$.

Megjegyzés: A fordított tételt nem bizonyítjuk.

A tananyaghoz kapcsolódó weboldal

<http://www.swisseduc.ch/compscience/exorciser/download.html>

Ezen a helyen sok a tananyagban szereplő algoritmus megtalálható és kipróbálható.

Köszönöm a figyelmet!