

Valószínűségszámítás és Statisztika

8. előadás
2020. április 7.

Likelihood függvény

Def.: A ξ_1, \dots, ξ_n független, azonos eloszlású minta likelihood függvénye

$$L(\mathbf{x}, \theta) = \begin{cases} P_{\theta}(\boldsymbol{\xi} = \mathbf{x}) = \prod_{i=1}^n P_{\theta}(\xi_i = x_i) & \text{diszkrét minta esetén} \\ f_{\theta}(\mathbf{x}) = \prod_{i=1}^n f_{\theta}(x_i) & \text{abszolút folytonos} \\ & \text{minta esetén} \end{cases}$$

ahol f_{θ} ξ_i sűrűségfüggvénye.

$l(\mathbf{x}, \theta) = \ln L(\mathbf{x}, \theta)$ a loglikelihood függvény.

Maximum likelihood becslés

- Definíció heurisztikusan: azt a paraméterértéket keressük, amelyre az adott minta bekövetkezési valószínűsége maximális.

Def.: θ maximum likelihood becslése $\hat{\theta} = T(\xi) \in \Theta$, ha

$$L(\xi, \hat{\theta}) = \max_{\theta \in \Theta} L(\xi, \theta)$$

Likelihood egyenlet

Gyakran a loglikelihood függvény maximumhelyét keresik a

$\frac{\partial l(\mathbf{x}, \theta)}{\partial \theta} = 0$ egyenletet (vagy egyenletrendszer) megoldva.

Ez diszkrét minta esetén a

$$\sum_{i=1}^n \frac{\partial \ln P_{\theta}(\xi_i = x_i)}{\partial \theta} = 0$$

egyenletet (vagy egyenletrendszer) jelenti.

Abszolút folytonos minta esetén

$$\sum_{i=1}^n \frac{\partial \ln f_{\theta}(x_i)}{\partial \theta} = 0$$

egyenletet (vagy egyenletrendszer) oldjuk meg.

Koronavírusos halálesetek száma

nap	Ausztria	Csehország	Magyarország	Szlovákia
01.ápr	20	7	1	0
02.ápr	18	8	4	0
03.ápr	12	5	1	0
04.ápr	10	9	11	0
05.ápr	18	6	2	0
06.ápr	18	8	4	0
átlag	16,0	7,2	3,8	0,0

Példa. (Poisson)

Tegyük fel, hogy $\eta_1, \eta_2, \dots, \eta_n \sim \text{Poisson}(\lambda)$. Ekkor

$$L(\underline{k}, \lambda) = P_\lambda(\eta_1 = k_1, \dots, \eta_n = k_n) = \prod_{i=1}^n \frac{\lambda^{k_i} e^{-\lambda}}{k_i!} = \left(\prod_{i=1}^n \frac{1}{k_i!} \right) \lambda^{\sum k_i} e^{-n\lambda}$$

$$\ell(\underline{k}, \lambda) = \ln L(\underline{k}, \lambda) = \left(\sum_{i=1}^n \ln \left(\frac{1}{k_i!} \right) \right) + \left(\sum_{i=1}^n k_i \right) \ln \lambda - n\lambda$$

$$\frac{\partial \ell}{\partial \lambda} = \frac{\sum k_i}{\lambda} - n = 0 \iff \lambda = \frac{\sum k_i}{n}$$

így az ML becslés

$$\hat{\lambda} = \frac{\sum \eta_i}{n}$$


Adottak sorszámozott gömbök (lottóhúzás) 1-től N -ig.
Visszatevésees húzás esetén becsüljük meg N -t!

$$P_N(\xi_i = k) = \frac{1}{N} \chi\{k \leq N\}$$

$$L(\underline{k}, \lambda) = P_N(\xi_1 = k_1, \dots, \xi_n = k_n) = \frac{1}{N^n} \chi\{\max_i k_i \leq N\}$$

$$\hat{N} = \max_i \xi_i$$

Kormányzati sport és rekreációs kiadások (M EUR)



Normális eloszlást feltételezve a paraméterek ML
becslése:

$$\hat{m} = 405 \text{ és } \hat{\sigma}^2 = 149\,284$$

Momentum módszer

- Ha az eloszlást k db paraméter határozza meg, akkor k db egyenletből kaphatunk rájuk becslést. Az egyenletek a tapasztalati és az elméleti momentumok egybevetéséből adódnak:

$$m_i(\underline{\theta}) = E_{\underline{\theta}}(X^i)$$

$$m_i(\underline{\theta}) = \frac{\sum_{j=1}^n (\xi_j)^i}{n}$$

Konfidenciaintervallum

- Olyan intervallum, mely legalább $1-\alpha$ valószínűséggel tartalmazza a keresett paramétert:

$$P_{\theta}(T_1(X) < \theta < T_2(X)) \geq 1 - \alpha$$

Példa (normális eloszlás)

- A Gyorskenyér Kft automata kenyérsütő készülékei egyszerre 100 kenyeret sütnek ki. Ezek tömegei grammban mérve $N(m, 10^2)$ eloszlással közelíthetők, ahol m a kezelő beállításától függ. Egy ellenőrzésnél megmérték mind a 100 kenyér tömegét. Az átlag 990 g volt. Készítsünk 95%-os megbízhatóságú konfidencia intervallumot m -re!

Konfidencia intervallum normális eloszlás várható értékére (ismert szórás esetén)

$$\xi_1, \dots, \xi_n \sim N(m, \sigma^2), \sigma \text{ ismert}, \Phi(u_y) = y \Rightarrow$$

$$P\left(\bar{\xi} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} < m < \bar{\xi} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha,$$

$$P\left(m > \bar{\xi} - u_{1-\alpha} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha,$$

$$P\left(m < \bar{\xi} + u_{1-\alpha} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

Konfidencia intervallum várható értékre (ismert szórás esetén)

$$\xi_1, \dots, \xi_n, E\xi_i = m, D^2\xi_i = \sigma^2, \sigma \text{ ismert} \Rightarrow$$

$$P\left(\bar{\xi} - \sqrt{\frac{1}{\alpha}} \frac{\sigma}{\sqrt{n}} < m < \bar{\xi} + \sqrt{\frac{1}{\alpha}} \frac{\sigma}{\sqrt{n}}\right) \geq 1 - \alpha.$$

$$\alpha \quad \boxed{u_{1-\alpha/2}} \quad \sqrt{\frac{1}{\alpha}}$$

10%	1,64	3,16
5%	1,96	4,47
2,50%	2,24	6,32
1%	2,58	10,00

Konfidencia intervallum "sok" megfigyelés esetén

$$\xi_1, \dots, \xi_n, D^2 \xi_i = \sigma^2 \text{ ismert} \Rightarrow$$

$$P\left(\bar{\xi} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} < m < \bar{\xi} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right) \sim 1 - \alpha.$$

Példák (milyen valószínűséggel születik fiúgyermek?)

- Svájcban 1871 és 1900 között a 2.644.757 megszületett gyermekből 1.359.671 fiú és 1.285.086 lány volt.
- Fiúk relatív gyakorisága így 0,5141.

$$p(1-p) \leq \frac{1}{4} \Rightarrow$$

$$P\left(\bar{\xi} - \frac{u}{2\sqrt{n}} < p < \bar{\xi} + \frac{u}{2\sqrt{n}}\right) \sim 2\Phi(u) - 1$$

Esetünkben 0,9973 valószínűséggel $0,5132 \leq p \leq 0,5150$


Konfidencia intervallum normális eloszlás várható értékére (ismeretlen szórás esetén)

- Ha a szórás nem ismert, becsüljük
- Tétel (biz. nélkül): normális eloszlású minta esetén a mintaátlag és a tapasztalati szórás független
- n szabadságfokú t (Student) eloszlás:

$$X_0, X_1, \dots, X_n \text{ *független* } N(0,1)$$

$$\frac{X_0}{\sqrt{(X_1^2 + \dots + X_n^2)/n}} \sim t_n$$

A t-eloszlás



Konfidencia intervallum normális eloszlás várható értékére (ismeretlen szórás esetén) (folyt.)

$$\xi_1, \dots, \xi_n \sim N(m, \sigma^2), \tilde{\sigma}^2 = \left((\xi_1 - \bar{\xi})^2 + \dots + (\xi_n - \bar{\xi})^2 \right) / (n-1) \Rightarrow$$

$$\frac{\sqrt{n}(\bar{\xi} - m)}{\sqrt{\tilde{\sigma}^2}} \sim t_{n-1}$$

$$P(t_{n-1} < t_{n-1,y}) = y$$

$$P\left(\bar{\xi} - t_{n-1,1-\alpha/2} \frac{\tilde{\sigma}}{\sqrt{n}} < m < \bar{\xi} + t_{n-1,1-\alpha/2} \frac{\tilde{\sigma}}{\sqrt{n}}\right) = 1 - \alpha,$$

$$P\left(m > \bar{\xi} - t_{n-1,1-\alpha} \frac{\tilde{\sigma}}{\sqrt{n}}\right) = 1 - \alpha,$$

$$P\left(m < \bar{\xi} + t_{n-1,1-\alpha} \frac{\tilde{\sigma}}{\sqrt{n}}\right) = 1 - \alpha$$

Példa (kenyér. folyt.)

- Tegyük fel most, hogy nem ismerjük Gyorskenyér Kft kenyereinek szórását. Az átlag 990 g volt.
- Ismert 10 szórásnál 991,6 g volt a 95%-os megbízhatóságú felső konfidencia határ.
- Amennyiben a korrigált tapasztalati szórás is 10, akkor ez a határ csak kis mértékben változik (991,8 g).
- Azonban 50-es korrigált tapasztalati szórásnál ez az érték 999 g-ra változik.

u és t együtthatók összehasonlítása

$$u_{1-5\%} = 1,64 \quad (\Phi(1,64) = 95\%)$$

n	$t_{n-1,1-5\%}$
2	6,31
3	2,92
4	2,35
5	2,13
10	1,83
20	1,73
50	1,68
100	1,66
1000	1,65

Hipotézisvizsgálat

- H_0 nullhipotézis (jelezni akarjuk, ha nem igaz)
 $\theta \in \Theta_0$.
- H_1 ellenhipotézis $\theta \in \Theta_1$.
- Elsőfajú hiba: H_0 igaz, de elutasítjuk
- Másodfajú hiba: H_0 hamis, de elfogadjuk
- Példák:
 - 2 kocka közül melyikkel dobunk?
 - mekkora a fejdobás valószínűsége?

Alapfogalmak

- Emlékeztető: \mathbf{X} mintatér: a minta lehetséges értékeinek halmaza.
- $\mathbf{X} = \mathbf{X}_e \cup \mathbf{X}_k$
- \mathbf{X}_k : azon lehetséges értékek halmaza, amelyek megfigyelése esetén elutasítjuk a nullhipotézist.
- Gyakran statisztika segítségével határozzuk meg:

$$T(\mathbf{x}) = \begin{cases} 1 & , \mathbf{x} \in \mathbf{X}_k \\ 0 & , \mathbf{x} \notin \mathbf{X}_k \end{cases}$$

Lehetséges döntések táblázata

		Aktuális helyzet	
		A nullhipotézis igaz	A nullhipotézis hamis
Döntés :	Elfogadjuk a nullhipotézist	Helyes döntés	Másodfajú hiba
	Elutasítjuk a nullhipotézist	Elsőfajú hiba	Helyes döntés

Elsőfajú hiba valószínűsége

α a próba terjedelme, ha minden $\mathcal{G} \in \Theta_0$ -ra

$$P_{\mathcal{G}}(\xi \in X_k) \leq \alpha$$


α a próba szignifikanciaszintje

(másképp: a próba pontos terjedelme),

$$\sup_{\mathcal{G} \in \Theta_0} P_{\mathcal{G}}(\xi \in X_k) = \alpha$$

Példa (egyetlen megfigyelés)


H_0 : a megfigyelés $N(4,1)$ eloszlású




Példa (sörök megkülönböztetése)

- Ki tudják-e választani a különböző sört?
- 24 emberen kísérleteztek.


$$H_0 : p = \frac{1}{3}, \quad H_1 : p > \frac{1}{3}$$



Lowe nbra u



Miller



Miller

Az eloszlás H_0 esetén




Figure 6: Distribution of Number of Correct Guesses with $p = \frac{1}{3}$

Kritikus tartomány megválasztása



$$P(\text{type I error}) = P(\text{Rejecting } H_0 | H_0 \text{ is true})$$

$$= P\left(y \geq y_c | p = \frac{1}{3}\right)$$

$$= \sum_{y=y_c}^{24} \binom{24}{y} \left(\frac{1}{3}\right)^y \left(\frac{2}{3}\right)^{24-y}$$


$$p\text{-value} = \sum_{y=11}^{24} \binom{24}{y} \left(\frac{1}{3}\right)^y \left(\frac{2}{3}\right)^{24-y} = 0.14$$

$$y_c = 12, P(\text{type I error}) = 0.0677 > 0.05$$

$$y_c = 13, P(\text{type I error}) = 0.0284 < 0.05$$

Másodfajú hiba valószínűsége

$$P_{\mathcal{G}}(\xi \in X_e), \mathcal{G} \in \Theta_1$$



Példa (sörös)

- $p=0.5$ esetén a másodfajú hiba valószínűsége

$$= P[Y \leq 12 \mid p = 0.5]$$
$$= 0.581$$




Figure 9: Distribution of Number of Correct Guesses with $p = 0.7$





Figure 8: Distribution of Number of Correct Guesses with $p = \frac{1}{2}$

Erőfüggvény

A próba erőfüggvénye

$$\beta(\vartheta) = P_{\vartheta}(\xi \in X_k) = 1 - P_{\vartheta}(\xi \in X_e), \vartheta \in \Theta_1$$




10 ezer ember koronavírusos tesztelése

- $H_0: p = 0,2\%$
- $H_1: p > 0,2\%$
- Teljesen hasonló az előző példához
- $\geq c$ fertőzött esetén elutasítjuk a nullhipotézist

c	Elsőfajú hiba valószínűsége
26	0.11196181
27	0.07768084
28	0.05230280
29	0.03418834
30	0.02170562

Próba ereje $c=28$ esetén



<i>p</i>	erő
2*2‰	0.1222548
3*2‰	0.2320277
4*2‰	0.3728980
5*2‰	0.5252410
6*2‰	0.6674264

Véletlenített próba

- Eddig adott megfigyelés esetén egyértelmű volt a döntésünk:

$$T(\mathbf{x}) = \begin{cases} 1 & , \mathbf{x} \in \mathbf{X}_k \\ 0 & , \mathbf{x} \notin \mathbf{X}_k \end{cases}$$

Véletlenített próba esetén sorolhatunk is:

$$\Psi(\mathbf{x}) = \begin{cases} 1 & , \text{ha } T(\mathbf{x}) > c \\ \gamma & , \text{ha } T(\mathbf{x}) = c \\ 0 & , \text{ha } T(\mathbf{x}) < c \end{cases}$$

Elsőfajú hiba valószínűsége véletlenített próba esetén

$\mathcal{G} \in \Theta_0$ -ra az elsőfajú hiba valószínűsége:

$$P_{\mathcal{G}}(T(\xi) > c) + \gamma P_{\mathcal{G}}(T(\xi) = c) = E_{\mathcal{G}}(\psi(\xi))$$

α a próba terjedelme, ha minden $\mathcal{G} \in \Theta_0$ -ra

$$E_{\mathcal{G}}(\psi(\xi)) \leq \alpha$$

α a próba szignifikanciaszintje

(másképp: a próba pontos terjedelme),

$$\sup_{\mathcal{G} \in \Theta_0} E_{\mathcal{G}}(\psi(\xi)) = \alpha$$

Legerősebb próba egyszerű hipotézis esetében

Egyszerű H_0 és $H_1 : |\Theta_0| = |\Theta_1| = 1$.

ψ a legerősebb α -terjedelmű próba, ha:

$$P_{g_0}(T(\xi) > c) + \gamma P_{g_0}(T(\xi) = c) = E_{g_0}(\psi(\xi)) \leq \alpha,$$

továbbá minden más α -terjedelmű ψ' próbára, annak másodfajú hibavalószínűsége nagyobb:

$$E_{g_1}(1 - \psi(\xi)) \leq E_{g_1}(1 - \psi'(\xi)).$$

A legerősebb próba

- A legegyszerűbb eset: H_0 és H_1 is egyszerű (egyelemű). A valószínűséghányados (vh.) próba:
- Állítás (Neyman-Pearson lemma): a vh. próba legerősebb a saját terjedelmével. Minden $0 < \alpha < 1$ -hez létezik ilyen terjedelmű vh. próba. Minden legerősebb próba ilyen alakú.

$$T(\mathbf{x}) = \begin{cases} 1 & \frac{L_1(\mathbf{x})}{L_0(\mathbf{x})} > c \\ \gamma & \frac{L_1(\mathbf{x})}{L_0(\mathbf{x})} = c \\ 0 & \frac{L_1(\mathbf{x})}{L_0(\mathbf{x})} < c \end{cases}$$

Paraméteres próbák

- Lényeg: valamilyen, véges sok valós paraméterrel leírható modellt tételezünk fel a mintáról.
- Példa:
 - Normális
 - indikátoreloszlású minta
- A feladat: a paraméter(ek)re vonatkozó hipotézis vizsgálata.

Próbák a normális eloszlás várható értékére: u-próba.

- $H_0: m = m_0$, $H_1: m \neq m_0$. Ha ismert a szórás (u-próba):

$$U = \sqrt{n} \frac{\bar{X} - m_0}{\sigma}$$

- Kritikus tartomány: $|u| > u_{1-\alpha/2}$. ($u_{1-\alpha/2}$ a standard normális eloszlás $1 - \alpha/2$ kvantilise)
- Ha egyoldali az ellenhipotézis, akkor a kritikus tartomány $u > u_{1-\alpha}$ ($m > m_0$), illetve $u < -u_{1-\alpha}$ alakú ($m < m_0$). Ezek legerősebb próbák!

U-próba

$\xi_1, \dots, \xi_n \sim N(m, \sigma^2)$, m ismeretlen, σ ismert.

$$H_0 : m = m_0$$

$$H_1 : m \neq m_0 \text{ (kétoldali ellenhipotézis)}$$

$$H_1' : m < m_0 \text{ (egyoldali ellenhipotézis)}$$

$$H_1'' : m > m_0 \text{ (egyoldali ellenhipotézis)}$$

$$U = \frac{\bar{\xi} - m_0}{\sigma} \sqrt{n}$$

$$H_0 \Rightarrow U \sim N(0,1)$$

$$H_1 \Rightarrow U \sim N\left(\frac{m - m_0}{\sigma} \sqrt{n}, 1\right)$$

U – próba (kétoldali ellenhipotézis)

$$\Phi(u_y) = y$$

$$X_k = \left\{ \mathbf{x} : \left| \frac{\bar{x} - m_0}{\sigma} \sqrt{n} \right| \geq u_{1-\alpha/2} \right\} \Rightarrow$$

$$\begin{aligned} P_{m_0}(\xi \in X_k) &= P_{m_0}(|U| \geq u_{1-\alpha/2}) = 1 - \Phi(u_{1-\alpha/2}) + \Phi(-u_{1-\alpha/2}) = \\ &= 1 - (1 - \alpha/2) + 1 - (1 - \alpha/2) = \alpha. \end{aligned}$$

$$\beta(m) = P_m(\xi \in X_k) = P_m(|U| \geq u_{1-\alpha/2}) =$$

$$1 - P_m(-u_{1-\alpha/2} < U < u_{1-\alpha/2}) = 1 - P_m\left(-u_{1-\alpha/2} < \frac{\bar{\xi} - m}{\sigma} \sqrt{n} + \frac{m - m_0}{\sigma} \sqrt{n} < u_{1-\alpha/2}\right) =$$

$$1 - P_m\left(-u_{1-\alpha/2} - \frac{m - m_0}{\sigma} \sqrt{n} < \frac{\bar{\xi} - m}{\sigma} \sqrt{n} < u_{1-\alpha/2} - \frac{m - m_0}{\sigma} \sqrt{n}\right) =$$

$$1 - \Phi\left(u_{1-\alpha/2} - \frac{m - m_0}{\sigma} \sqrt{n}\right) + \Phi\left(-u_{1-\alpha/2} - \frac{m - m_0}{\sigma} \sqrt{n}\right) \xrightarrow{n \rightarrow \infty} 1, m \neq m_0$$