

Relációs algebrai optimalizálás

- A lekérdezések optimalizálásának folyamata
- Az algebrai optimalizálás szerepe, célja
- 11 ekvivalencia szabálytípus
- Az algebrai optimalizálás heurisztikus megadása
- Az algoritmus formálisan
- Példa

Lekérdezések optimalizálása

CÉL: A lekérdezéseket gyorsabbá akarjuk tenni a táblákra vonatkozó paraméterek, statisztikák, indexek ismeretében és általános érvényű tulajdonságok, heurisztikák segítségével.

Például, hogyan, milyen procedúrával értékeljük ki az alábbi SQL (deklaratív) lekérdezést?

Legyen adott $R(A,B,C)$ és $S(C,D,E)$. Melyek azok az $R.B$ és $S.D$ értékek azokban az R , illetve S táblabeli sorokban, amely sorokban $R.A='c'$ és $S.E=2$ és $R.C=S.C$?

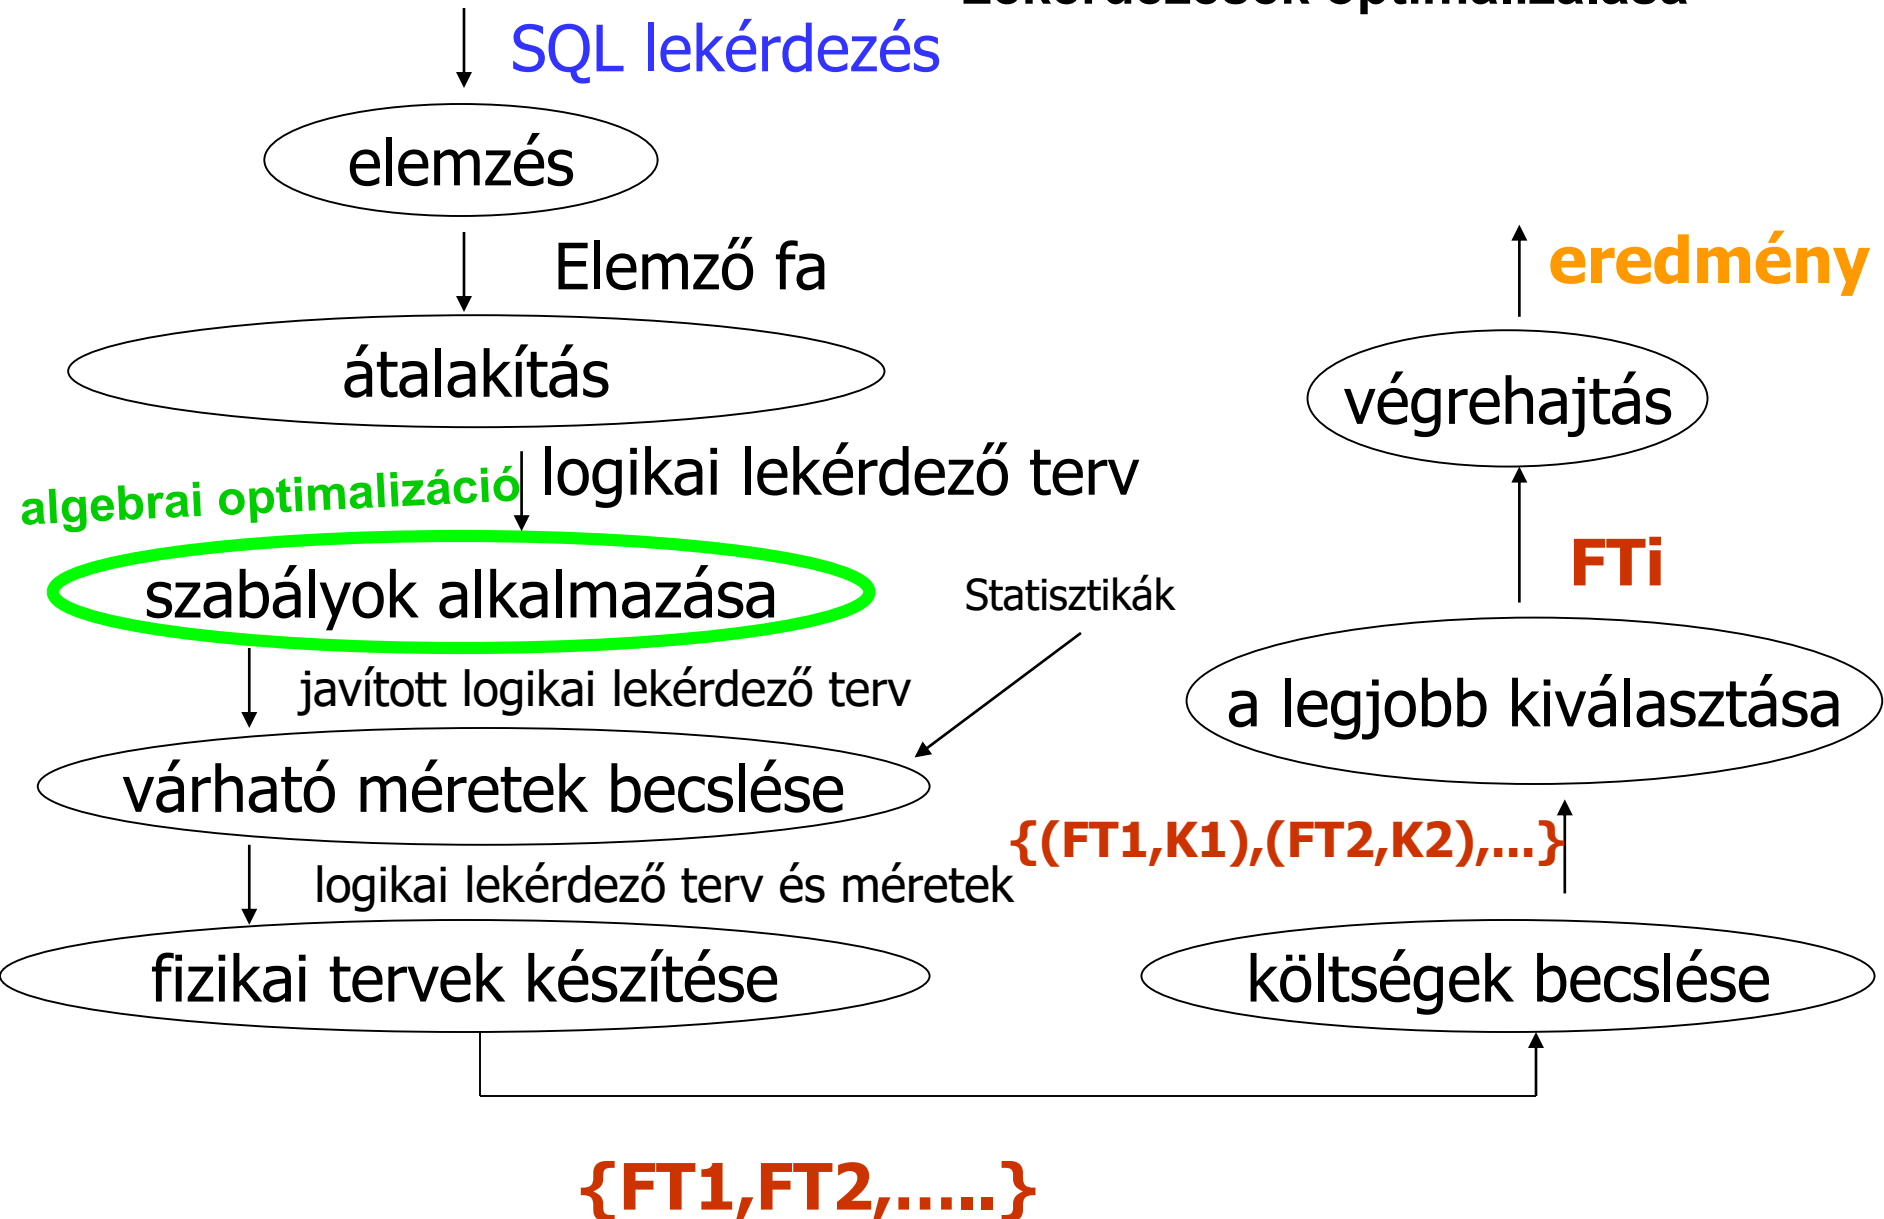
Ugyanez SQL-ben:

Select B,D

From R,S

Where $R.A = 'c'$ and $S.E = 2$ and $R.C=S.C$;

Lekérdezések optimalizálása



Lekérdezések optimalizálása

R	A	B	C	S	C	D	E
	a	1	10		10	x	2
	b	1	20		20	y	2
	c	2	10		30	z	2
	d	2	35		40	x	1
	e	3	45		50	y	3

**A lekérdezés
eredménye:**

B	D
2	x

Select B,D From R,S
Where R.A = 'c' and
S.E = 2 and
R.C=S.C;

Lekérdezések optimalizálása

Hogy számoljuk ki tetszőleges tábla esetén az eredményt?

Egy lehetséges terv

- Vegyünk a két tábla szorzatát!
- Válasszuk ki a megfelelő sorokat!
- Hajtsuk végre a vetítést!

$\Pi_{B,D} [\sigma_{R.A='c' \wedge S.E=2 \wedge R.C = S.C} (RXS)]$

- Ez a direktszorzaton alapuló összekapcsolás.
- Oracleben: NESTED LOOP.
- Nagyon költséges!

RXS

R.A	R.B	R.C	S.C	S.D	S.E
a	1	10	10	x	2
a	1	10	20	y	2
.					
.					
c	2	10	10	x	2
.					
.					

Ez a
sor kell!

B **D**


2

x

$\Pi_{B,D} [\sigma_{R.A='c' \wedge S.E=2 \wedge R.C = S.C} (RXS)]$

Lekérdezések optimalizálása

Ugyanez a terv relációs algebrában:



$\Pi_{B,D} [\sigma_{R.A='c' \wedge S.E=2 \wedge R.C=S.C} (RXS)]$

Lekérdezések optimalizálása

R

A	B	C
a	1	10
b	1	20
c	2	10
d	2	35
e	3	45

$\sigma(R)$


A	B	C
c	2	10

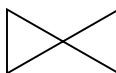
$\sigma(S)$

C	D	E
10	x	2
20	y	2
20	y	2
30	z	2

S

C	D	E
10	x	2
20	y	2
30	z	2
40	x	1
50	y	3





 $\Pi_{B,D}$

Ugyanazt számolja ki!

B	D
2	x

Lekérdezések optimalizálása

Egy másik lehetséges kiszámítási javaslat:



$\Pi_{B,D} [\sigma_{R.A='c'} \wedge S.E=2 \wedge R.C = S.C \text{ (RXS)}]$

helyett


$\Pi_{B,D} [\sigma_{R.A='c'} (R) \bowtie \sigma_{S.E=2} (S)]$

Lekérdezések optimalizálása

Használjuk ki az R.A és S.C oszlopokra készített **indexeket**:

- (1) Az **R.A index alapján keressük** meg az R azon sorait, amelyekre $R.A = 'c'$!
- (2) Minden megtalált R.C értékhez az **S.C index alapján keressük** meg az S-ből az ilyen értékű sorokat!
- (3) **Válasszuk ki** a kapott S-beli sorok közül azokat, amelyekre $S.E = 2$!
- (4) **Kapcsoljuk össze** az R és S így kapott sorait, és végül **vetítsünk** a B és D oszlopokra.

Lekérdezések optimalizálása



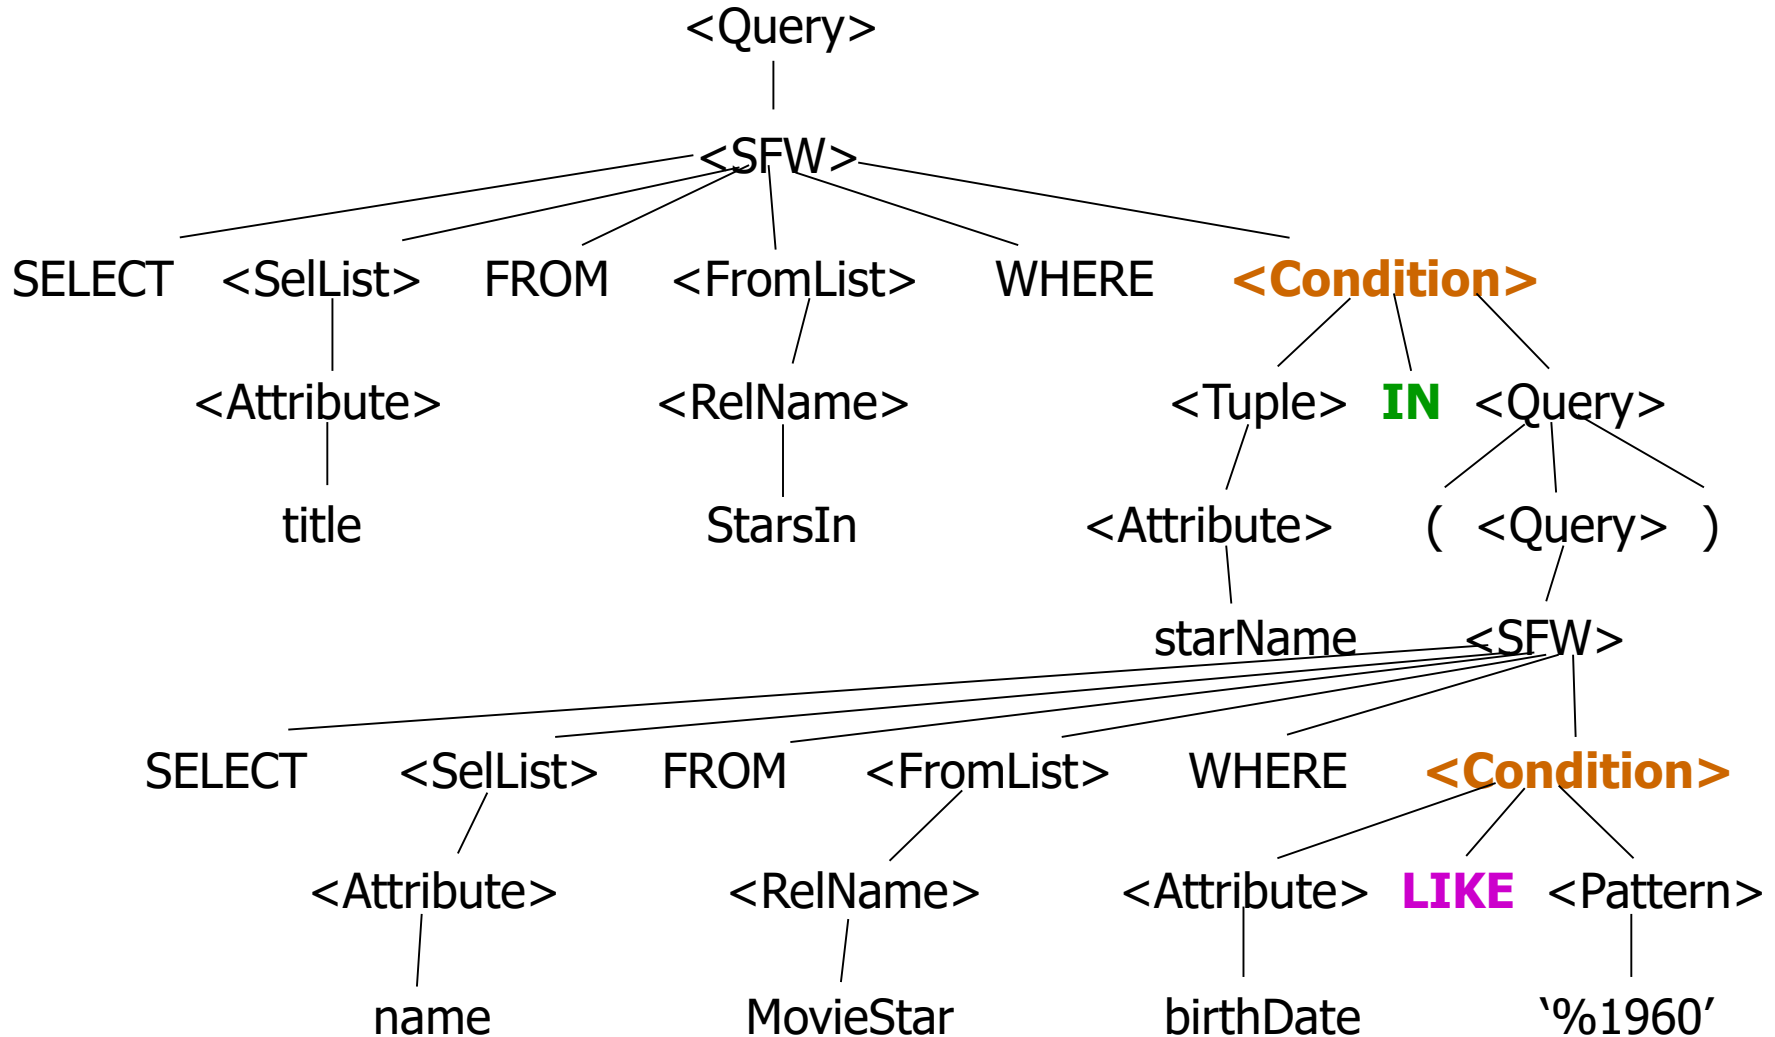
INDEXES ÖSSZEKAPCSOLÁS

Példa: SQL lekérdezés

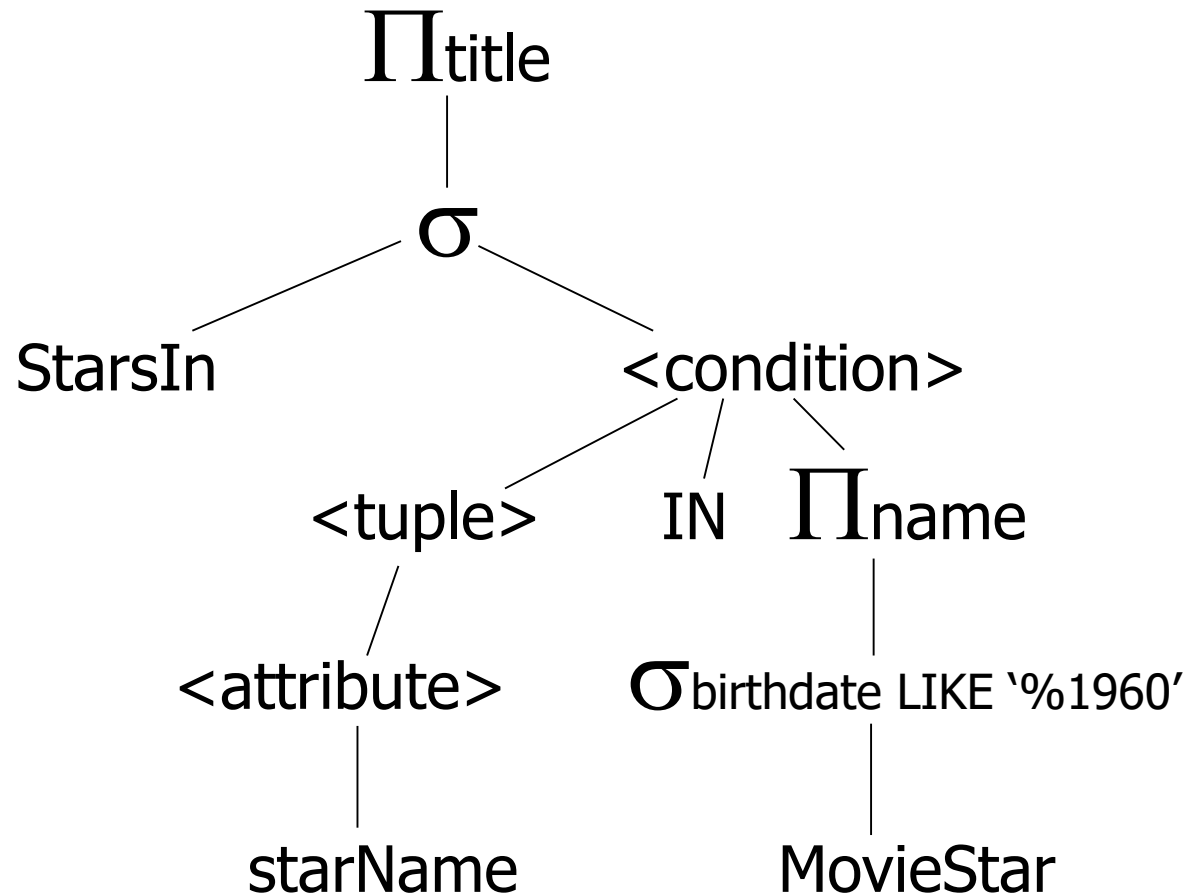
```
SELECT title  
FROM StarsIn  
WHERE starName IN (  
    SELECT name  
    FROM MovieStar  
    WHERE birthdate LIKE '%1960'  
);
```

Milyen filmekben szerepeltek 1960-as születésű színészek?


Elemzőfa: Parse Tree




Ugyanez reláció algebraiban:



Átalakított logikai lekérdező terv



Továbbjavított logika lekérdező terv



Algebrai optimalizáció

- **Cél:** a relációs algebrai kifejezéseket minél gyorsabban akarjuk kiszámolni.
- **Költségmodell:** a kiszámítás költsége arányos a relációs algebrai kifejezés részkifejezéseinek megfelelő relációk tárolási méreteinek összegével.
- **Módszer:** a műveleti tulajdonságokon alapuló ekvivalens átalakításokat alkalmazunk, hogy várhatóan kisebb méretű relációk keletkezzenek.
- **Az eljárás heurisztikus**, tehát nem az argumentum relációk valódi méretével számol.
- **Az eredmény nem egyértelmű:** Az átalakítások sorrendje nem determinisztikus, így más sorrendben végrehajtva az átalakításokat más végeredményt kaphatunk, de mindegyik általában jobb költségű, mint amiből kiindultunk.
- **Megjegyzés:** Mivel az SQL bővebb, mint a relációs algebra, ezért az optimalizálást bővített relációs algebrára is meg kell adni, de először a hagyományos algebrai kifejezéseket vizsgáljuk.

Algebrai optimalizáció

- A relációs algebrai kifejezést **gráffal** ábrázoljuk.
- **Kifejezésfa:**
 - a **nem levél csúcsok**: a relációs algebrai műveletek:
 - **unáris** (σ, Π, ρ) – egy gyereke van
 - **bináris** ($-, \cup, \times$) – két gyereke van (bal oldali az első, jobb oldali a második argumentumnak felel meg)
 - a **levél csúcsok**: konstans relációk vagy relációs változók

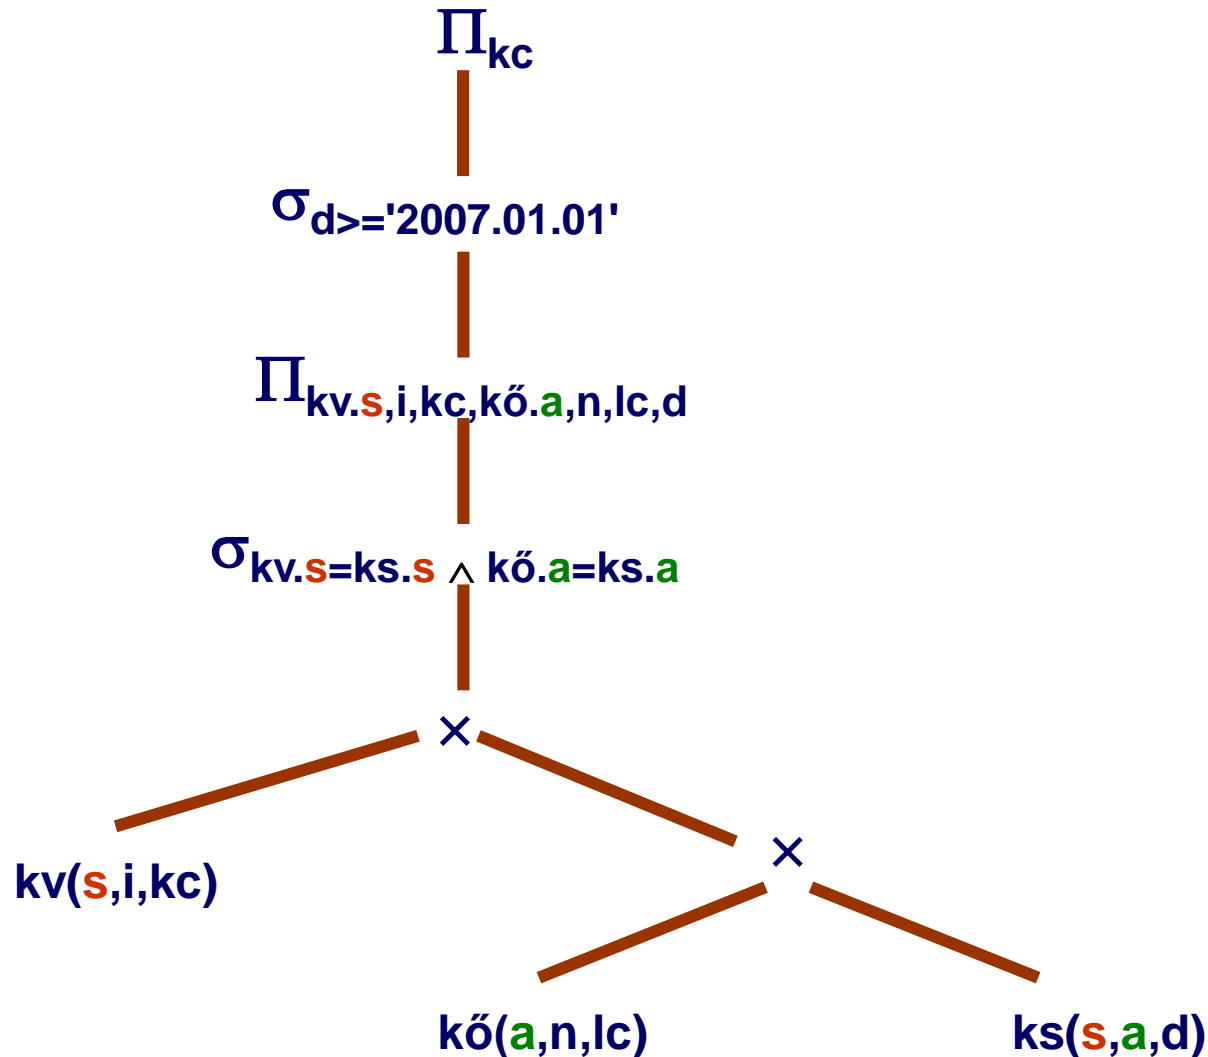
Algebrai optimalizáció

- könyv(sorszám,író,könyvcím)
 - kv(**s**,i,kc)
- kölcsönző(azonosító,név,lakcím)
 - kő(**a**,n,lc)
- kölcsönzés(sorszám,azonosító,dátum)
 - ks(**s**,**a**,d)
- Milyen című könyveket kölcsönöztek ki 2007-től kezdve?
- $\Pi_{kc}(\sigma_{d \geq '2007.01.01'}(kv \times |kő| \times |ks))$
- Az összekapcsolásokat valamilyen sorrendben kifejezzük az alpműveletekkel:

$$\Pi_{kc}(\sigma_{d \geq '2007.01.01'}(\Pi_{kv.s,i,kc,kő.a,n,lc,d}(\sigma_{kv.s=ks.s \wedge kő.a=ks.a}(kv \times (kő \times ks))))))$$

Algebrai optimalizáció

$\Pi_{kc}(\sigma_{d \geq '2007.01.01'}(\Pi_{kv.s, i, kc, k\acute{o}.a, n, lc, d}(\sigma_{kv.s=ks.s \wedge k\acute{o}.a=ks.a}(kv \times (k\acute{o} \times ks))))))$



Algebrai optimalizáció

- $E_1(r_1, \dots, r_k)$ és $E_2(r_1, \dots, r_k)$ **relációs algebrai kifejezések ekvivalensek** ($E_1 \cong E_2$), ha tetszőleges r_1, \dots, r_k relációkat véve $E_1(r_1, \dots, r_k) = E_2(r_1, \dots, r_k)$.
- **11 szabályt** adunk meg. A szabályok olyan állítások, amelyek kifejezések ekvivalenciáját fogalmazzák meg. Bizonyításuk könnyen végiggondolható.
- Az állítások egy részében a kifejezések szintaktikus helyessége egyben elégséges feltétele is az ekvivalenciának.

1. Kommutativitás (szorzás, természetes összekapcsolás, téta-összekapcsolás)

- $E1 \times E2 \cong E2 \times E1$
- $E1 \mid \times \mid E2 \cong E2 \mid \times \mid E1$
- $E1 \mid \times \mid E2 \cong E2 \mid \times \mid E1$

Algebrai optimalizáció

2. Asszociativitás (szorzás, természetes összekapcsolás, téta-összekapcsolás)

- $(E1 \times E2) \times E3 \cong E1 \times (E2 \times E3)$
- $(E1 \mid \times \mid E2) \mid \times \mid E3 \cong E1 \mid \times \mid (E2 \mid \times \mid E3)$
- $(E1 \mid \times \mid E2) \mid \times \mid E3 \cong E1 \mid \times \mid (E2 \mid \times \mid E3)$
 $\oplus \quad \oplus \quad \oplus \quad \oplus$

3. Vetítések összevonása, bővítése

- Legyen \underline{A} és \underline{B} két részhalmaza az E reláció oszlopainak úgy, hogy $\underline{A} \subseteq \underline{B}$.
- Ekkor $\Pi_{\underline{A}}(\Pi_{\underline{B}}(E)) \cong \Pi_{\underline{A}}(E)$.

4. Kiválasztások felcserélhetősége, felbontása

- Legyen $F1$ és $F2$ az E reláció oszlopain értelmezett kiválasztási feltétel.
- Ekkor $\sigma_{F1 \wedge F2}(E) \cong \sigma_{F1}(\sigma_{F2}(E)) \cong \sigma_{F2}(\sigma_{F1}(E))$.

Algebrai optimalizáció

5. Kiválasztás és vetítés felcserélhetősége

- Legyen F az E relációnak csak az \underline{A} oszlopain értelmezett kiválasztási feltétel.
- a) • Ekkor $\Pi_{\underline{A}}(\sigma_F(E)) \cong \sigma_F(\Pi_{\underline{A}}(E))$.
 - Általánosabban: Legyen F az E relációnak csak az $\underline{A} \cup \underline{B}$ oszlopain értelmezett kiválasztási feltétel, ahol $\underline{A} \cap \underline{B} = \emptyset$.
- b) • Ekkor $\Pi_{\underline{A}}(\sigma_F(E)) \cong \Pi_{\underline{A}}(\sigma_F(\Pi_{\underline{A} \cup \underline{B}}(E)))$.

6. Kiválasztás és szorzás felcserélhetősége

- Legyen F az E_1 reláció oszlopainak egy részhalmazán értelmezett kiválasztási feltétel.
- a) • Ekkor $\sigma_F(E_1 \times E_2) \cong \sigma_F(E_1) \times E_2$.
 - Speciálisan: Legyen $i=1,2$ esetén F_i az E_i reláció oszlopainak egy részhalmazán értelmezett kiválasztási feltétel, legyen továbbá $F = F_1 \wedge F_2$.
- b) • Ekkor $\sigma_F(E_1 \times E_2) \cong \sigma_{F_1}(E_1) \times \sigma_{F_2}(E_2)$.
 - Általánosabban: Legyen F_1 az E_1 reláció oszlopainak egy részhalmazán értelmezett kiválasztási feltétel, legyen F_2 az $E_1 \times E_2$ reláció oszlopainak egy részhalmazán értelmezett kiválasztási feltétel, úgy hogy mindkét sémából legalább egy oszlop szerepel benne, legyen továbbá $F = F_1 \wedge F_2$.
- c) • Ekkor $\sigma_F(E_1 \times E_2) \cong \sigma_{F_2}(\sigma_{F_1}(E_1) \times E_2)$.

Algebrai optimalizáció

7. Kiválasztás és egyesítés felcserélhetősége

- Legyen $E1$, $E2$ relációk sémája megegyező, és F a közös sémán értelmezett kiválasztási feltétel.
- Ekkor $\sigma_F(E1 \cup E2) \cong \sigma_F(E1) \cup \sigma_F(E2)$.

8. Kiválasztás és kivonás felcserélhetősége

- Legyen $E1$, $E2$ relációk sémája megegyező, és F a közös sémán értelmezett kiválasztási feltétel.
- Ekkor $\sigma_F(E1 - E2) \cong \sigma_F(E1) - \sigma_F(E2)$.

9. Kiválasztás és természetes összekapcsolás felcserélhetősége

- Legyen F az $E1$ és $E2$ közös oszlopainak egy részhalmazán értelmezett kiválasztási feltétel.
- Ekkor $\sigma_F(E1 \bowtie E2) \cong \sigma_F(E1) \bowtie \sigma_F(E2)$.

Algebrai optimalizáció

10. Vetítés és szorzás felcserélhetősége

- Legyen $i=1,2$ esetén $\underline{A_i}$ az E_i reláció oszlopainak egy halmaza, valamint legyen $\underline{A}=\underline{A_1}\cup\underline{A_2}$.
- Ekkor $\Pi_{\underline{A}}(E_1 \times E_2) \cong \Pi_{\underline{A_1}}(E_1) \times \Pi_{\underline{A_2}}(E_2)$.

11. Vetítés és egyesítés felcserélhetősége

- Legyen E_1 és E_2 relációk sémája megegyező, és legyen \underline{A} a sémában szereplő oszlopok egy részhalmaza.
- Ekkor $\Pi_{\underline{A}}(E_1 \cup E_2) \cong \Pi_{\underline{A}}(E_1) \cup \Pi_{\underline{A}}(E_2)$.
- Megjegyzés: **A vetítés és kivonás nem cserélhető fel**, azaz $\Pi_{\underline{A}}(E_1 - E_2) \neq \Pi_{\underline{A}}(E_1) - \Pi_{\underline{A}}(E_2)$. Például:

E1:

A	B
0	0
0	1

E2:

A	B
0	0
0	0

esetén $\Pi_{\underline{A}}(E_1 - E_2)$:

A
0

míg

$$\Pi_{\underline{A}}(E_1) - \Pi_{\underline{A}}(E_2) = \emptyset$$



Algebrai optimalizáció

- Az optimalizáló algoritmus a következő **heurisztikus elveken** alapul:
 1. **Minél hamarabb szelektáljunk**, hogy a részkifejezések várhatóan kisebb relációk legyenek.
 2. A szorzás utáni kiválasztásokból **próbáljunk természetes összekapcsolásokat képezni**, mert az összekapcsolás hatékonyabban kiszámolható, mint a szorzatból történő kiválasztás.
 3. **Vonjuk össze az egymás utáni unáris műveleteket** (kiválasztásokat és vetítéseket), és ezekből lehetőleg egy kiválasztást, vagy vetítést, vagy kiválasztás utáni vetítést képezzünk. Így csökken a műveletek száma, és általában a kiválasztás kisebb relációt eredményez, mint a vetítés.
 4. **Keressünk közös részkifejezéseket**, amiket így elég csak egyszer kiszámolni a kifejezés kiértékelése során.

Algebrai optimalizáció

- **Algebrai optimalizációs algoritmus:**
- **INPUT:** relációs algebrai kifejezés kifejezésfája
- **OUTPUT:** optimalizált kifejezésfa optimalizált kiértékelése

Hajtsuk végre az alábbi lépéseket a megadott sorrendben:

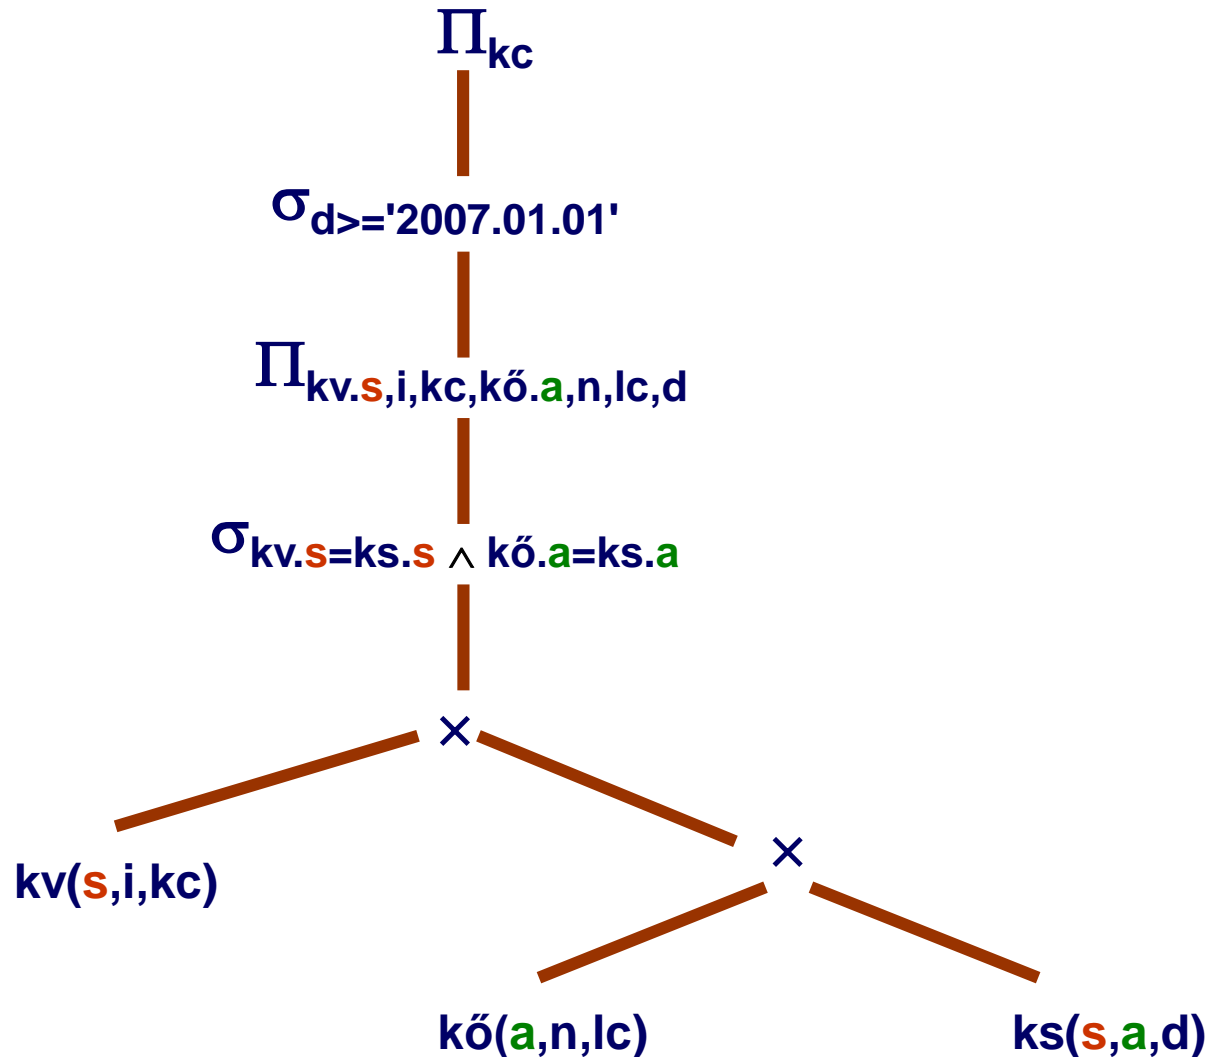
1. **A kiválasztásokat bontsuk fel** a **4. szabály** segítségével:
 - $\sigma_{F_1 \wedge \dots \wedge F_n}(E) \cong \sigma_{F_1}(\dots(\sigma_{F_n}(E)))$
2. **A kiválasztásokat** a **4., 5., 6., 7., 8., 9. szabályok** segítségével **vigyük** olyan **mélyre** a kifejezésfában, amilyen mélyre csak lehet.
3. **A vetítéseket** a **3., 5., 10., 11. szabályok** segítségével **vigyük** olyan **mélyre** a kifejezésfában, amilyen mélyre csak lehet. Hagyjuk el a triviális vetítéseket, azaz az olyanokat, amelyek az argumentum reláció összes attribútumára vetítenek.
4. Ha egy relációs változóra vagy konstans relációra közvetlenül egymás után kiválasztásokat vagy vetítéseket alkalmazunk, akkor ezeket a **3., 4., 5. szabályok** segítségével **vonjuk össze egy kiválasztássá, vagy egy vetítéssé, vagy egy kiválasztás utáni vetítéssé, ha lehet** (azaz egy $\Pi(\sigma())$ alakú kifejezéssé). **Ezzel megkaptuk az optimalizált kifejezésfát.**
5. A gráfot **a bináris műveletek alapján bontsuk részgráfokra**. Minden részgráf egy bináris műveletnek feleljen meg. A részgráf csúcsai legyenek: a bináris műveletnek ($\cup, \rightarrow, \times$) megfelelő csúcs és a csúcs felett a következő bináris műveletig szereplő kiválasztások (σ) és vetítések (Π). Ha a bináris művelet szorzás (\times), és a részgráf equi-joinnak felel meg, és a szorzás valamelyik ága nem tartalmaz bináris műveletet, akkor ezt az ágat is vegyük hozzá a részgráfhoz.
6. Az előző lépésben kapott részgráfok is fát képeznek. **Az optimális kiértékeléshez** ezt a fát értékeljük ki alulról felfelé haladva, tetszőleges sorrendben.

Megjegyzés. Az **equi-join** azt jelenti, hogy a kiválasztás feltétele egyenlőség, amely a szorzás két ágának egy-egy oszlopát hasonlítja össze.

Algebrai optimalizáció

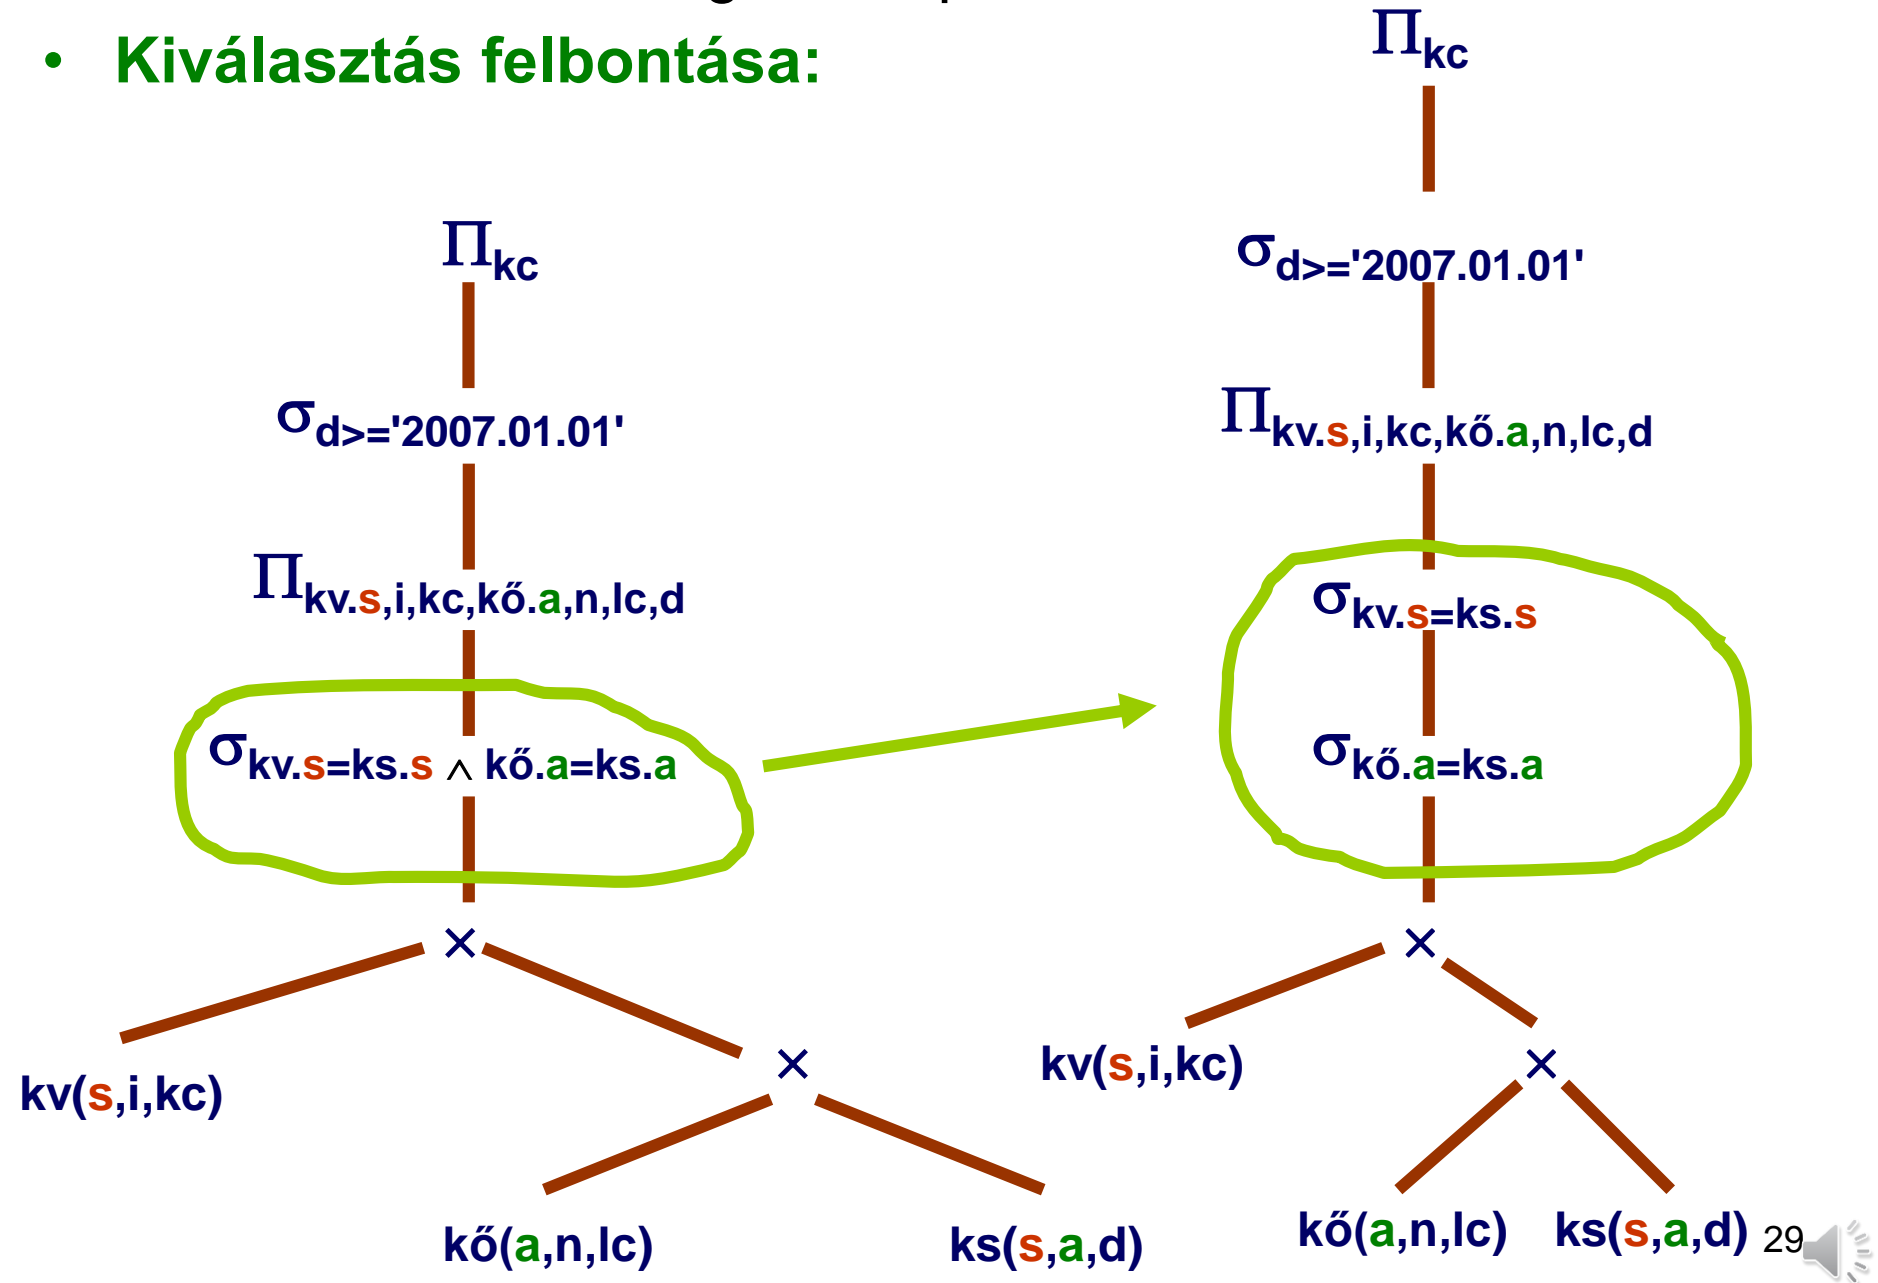
- Optimalizáljuk a következő kifejezést:

$$\Pi_{kc}(\sigma_{d \geq '2007.01.01'}(\Pi_{kv.s, i, kc, k\acute{o}.a, n, lc, d}(\sigma_{kv.s = ks.s \wedge k\acute{o}.a = ks.a}(kv \times (k\acute{o} \times ks)))))$$




Algebrai optimalizáció


- Kiválasztás felbontása:**




Algebrai optimalizáció



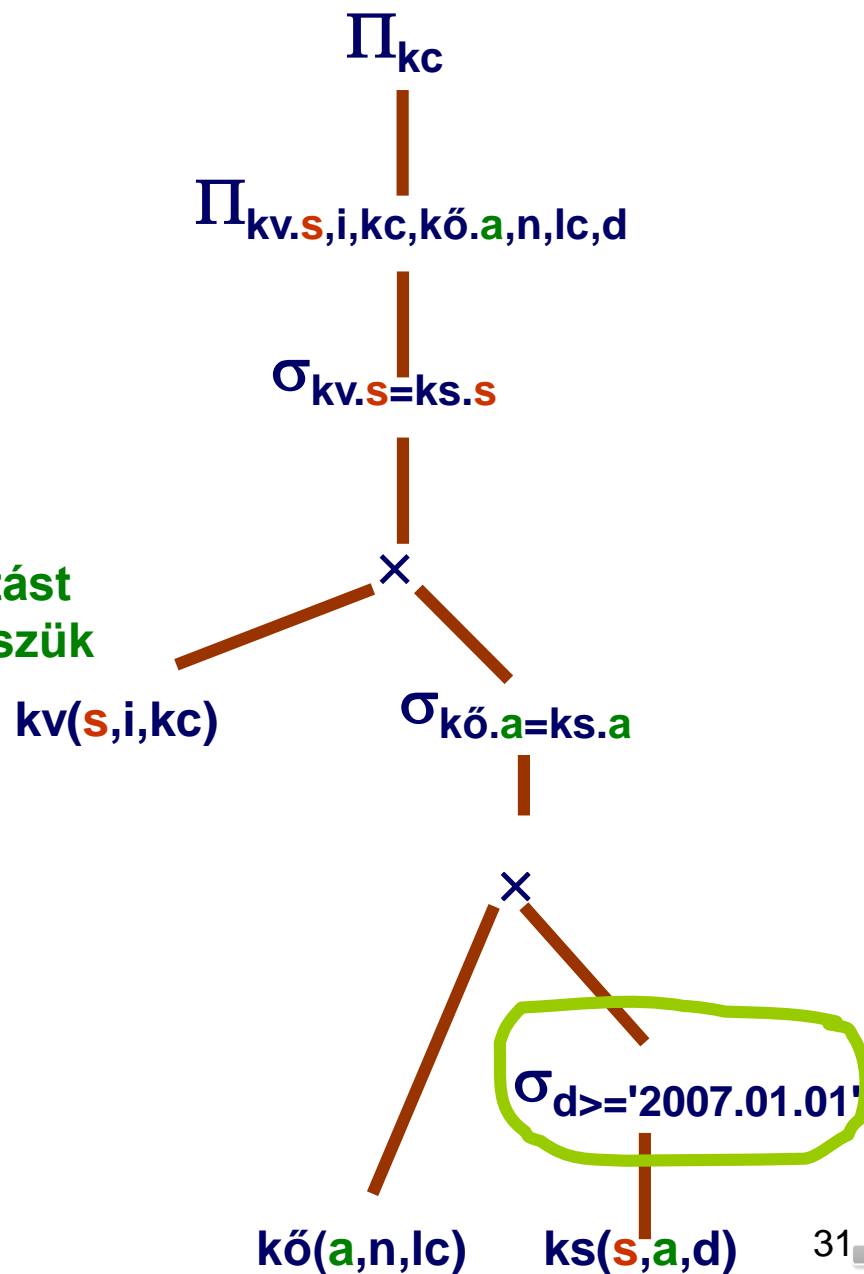
A kiválasztást
lejjebb visszük



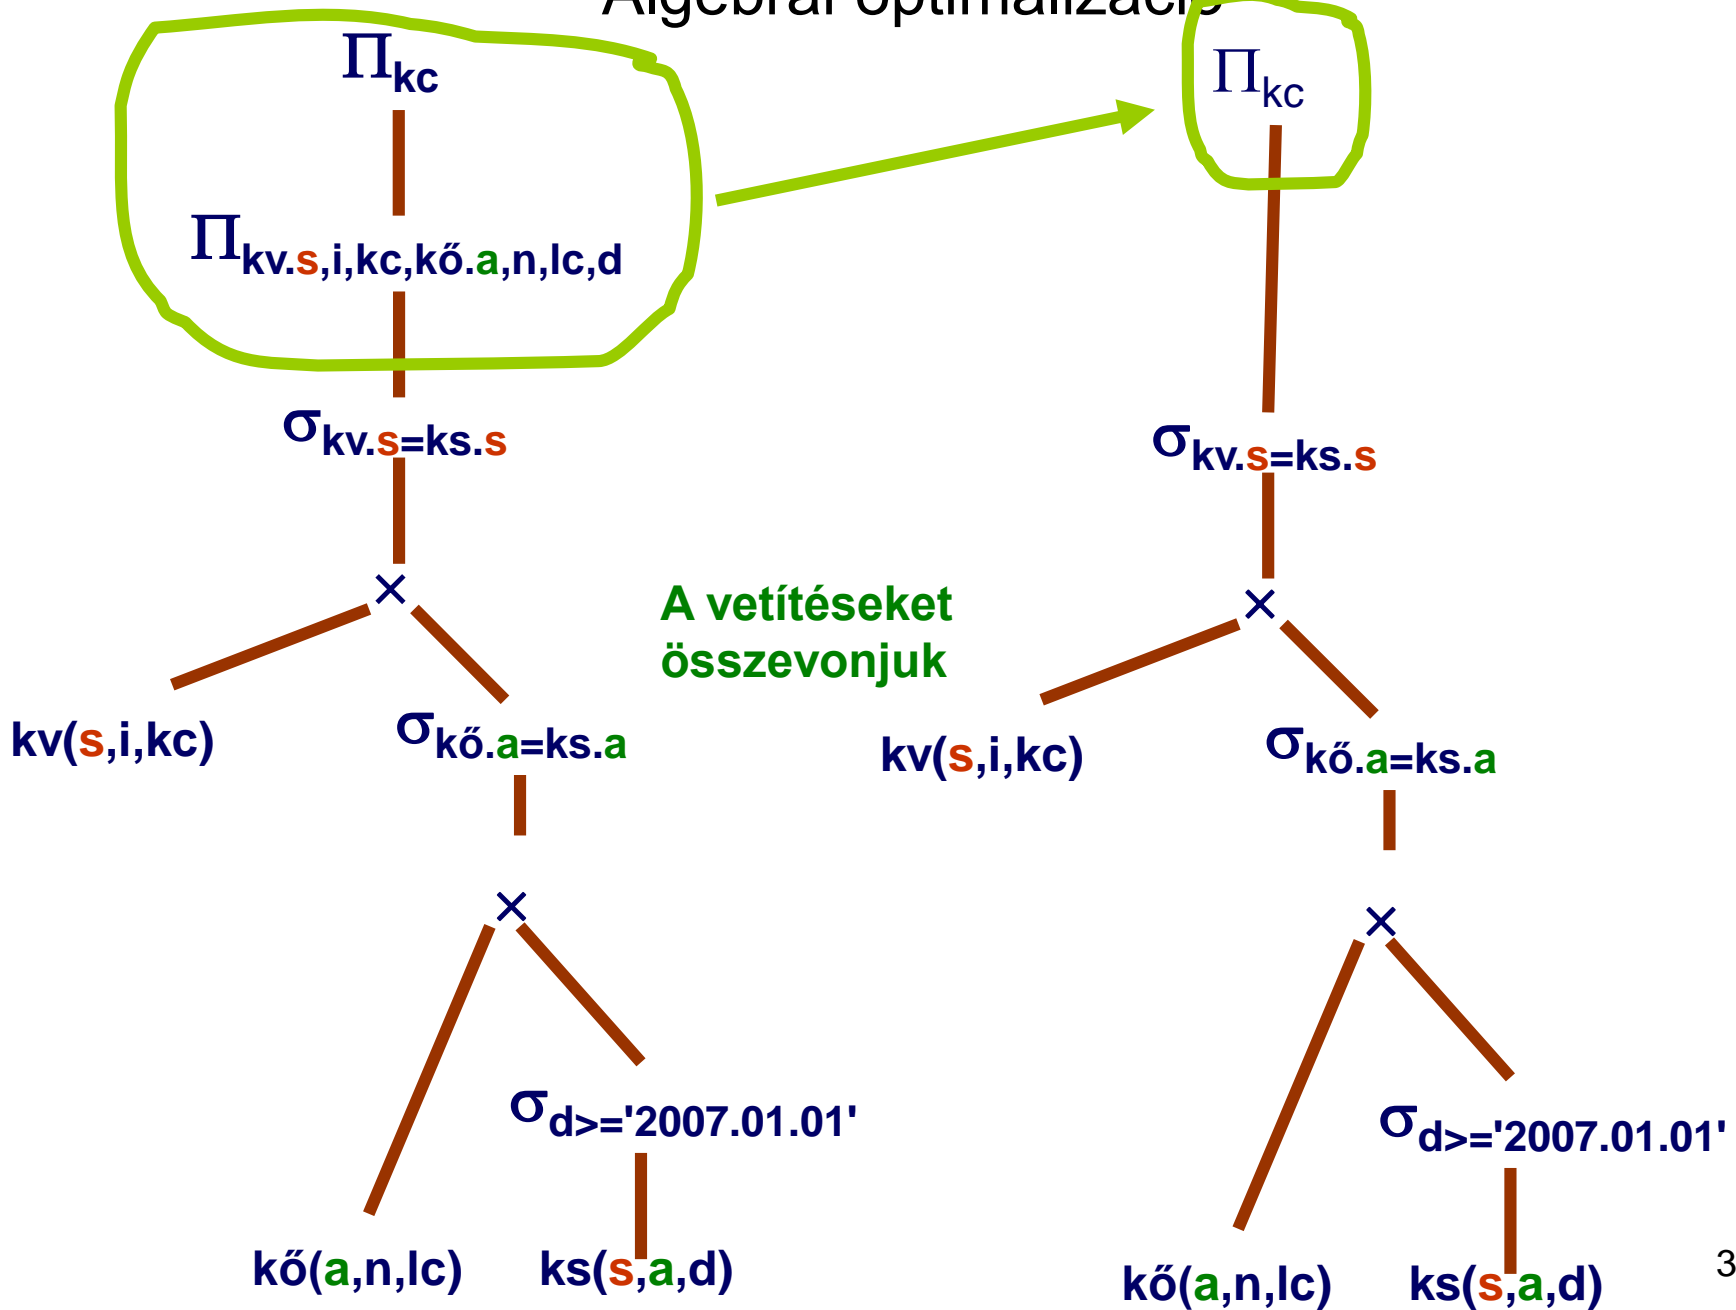
Algebrai optimalizáció



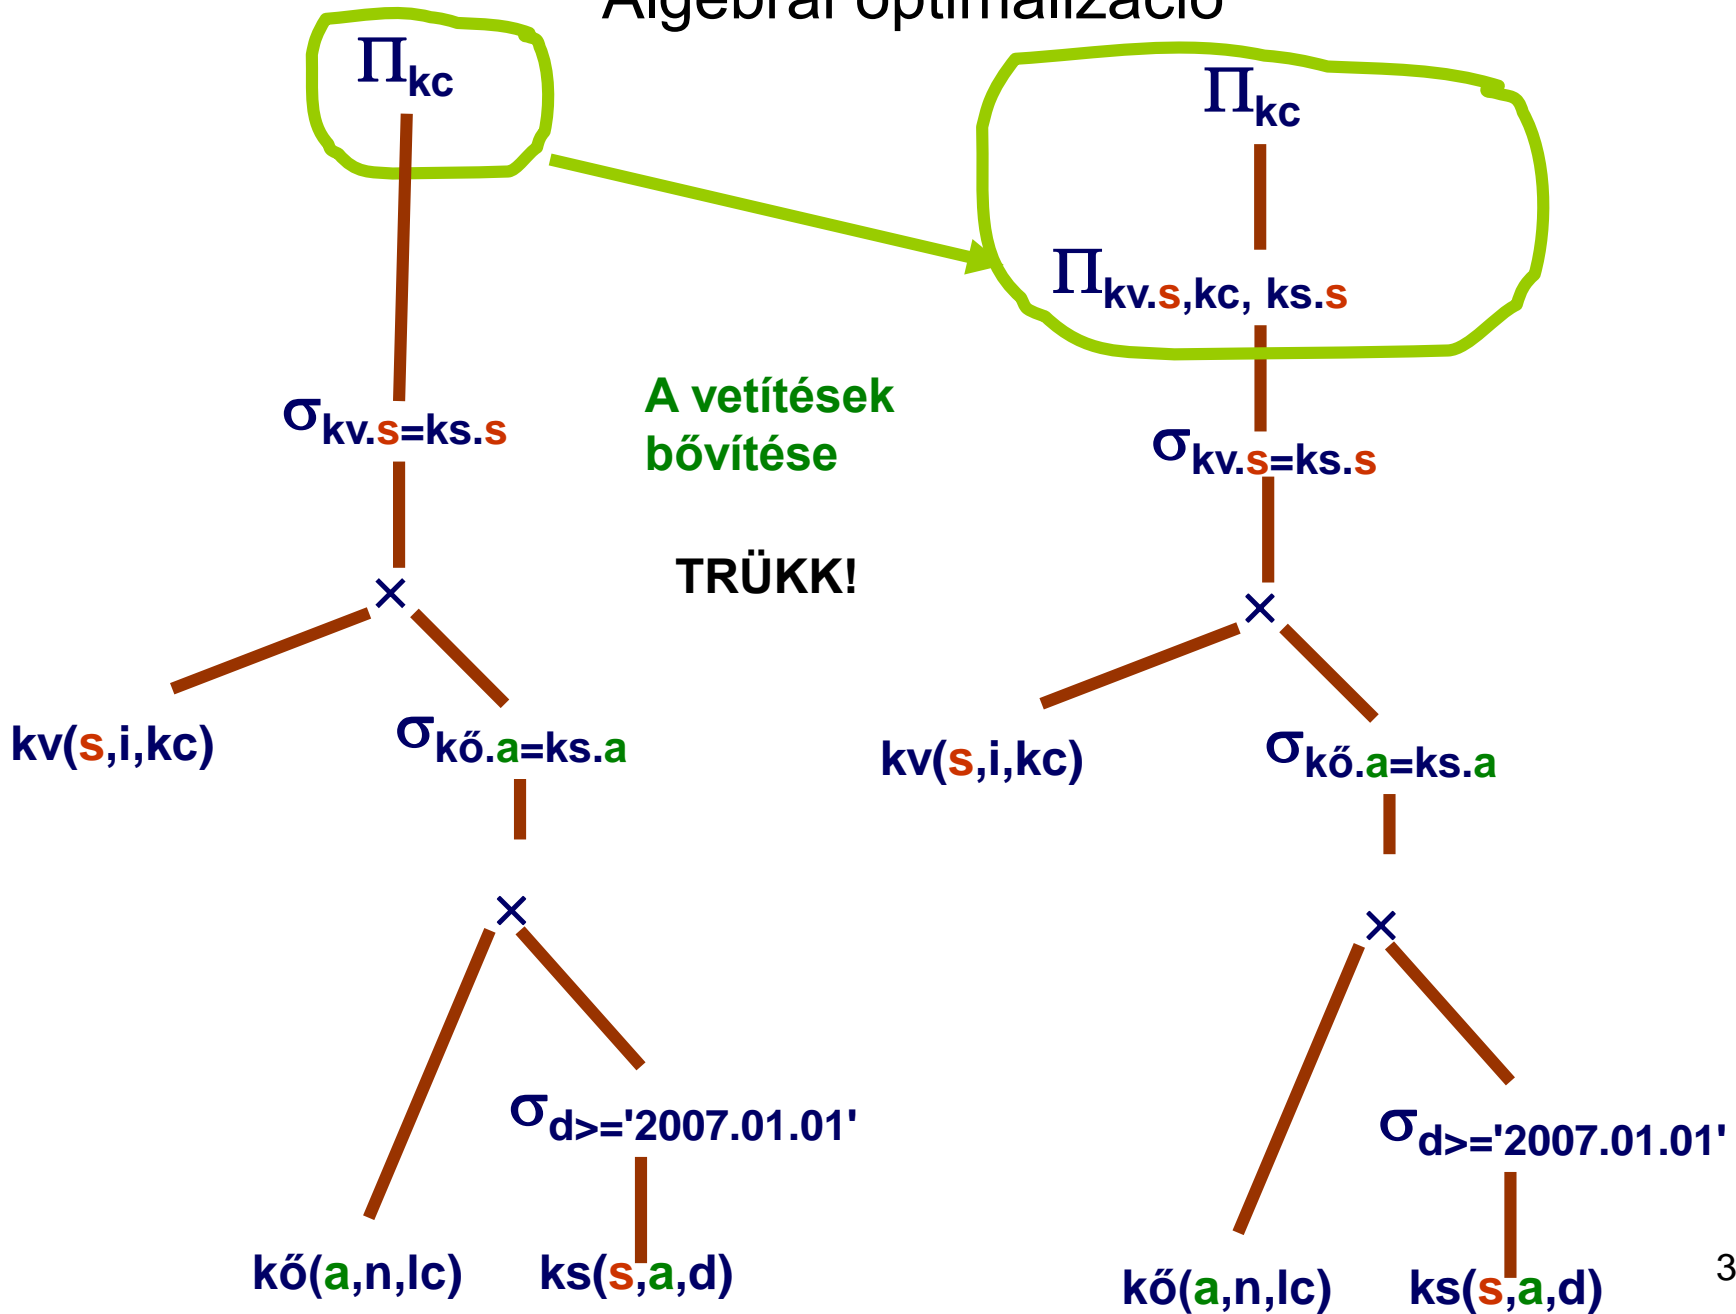
A kiválasztást
lejjebb visszük




Algebrai optimalizáció



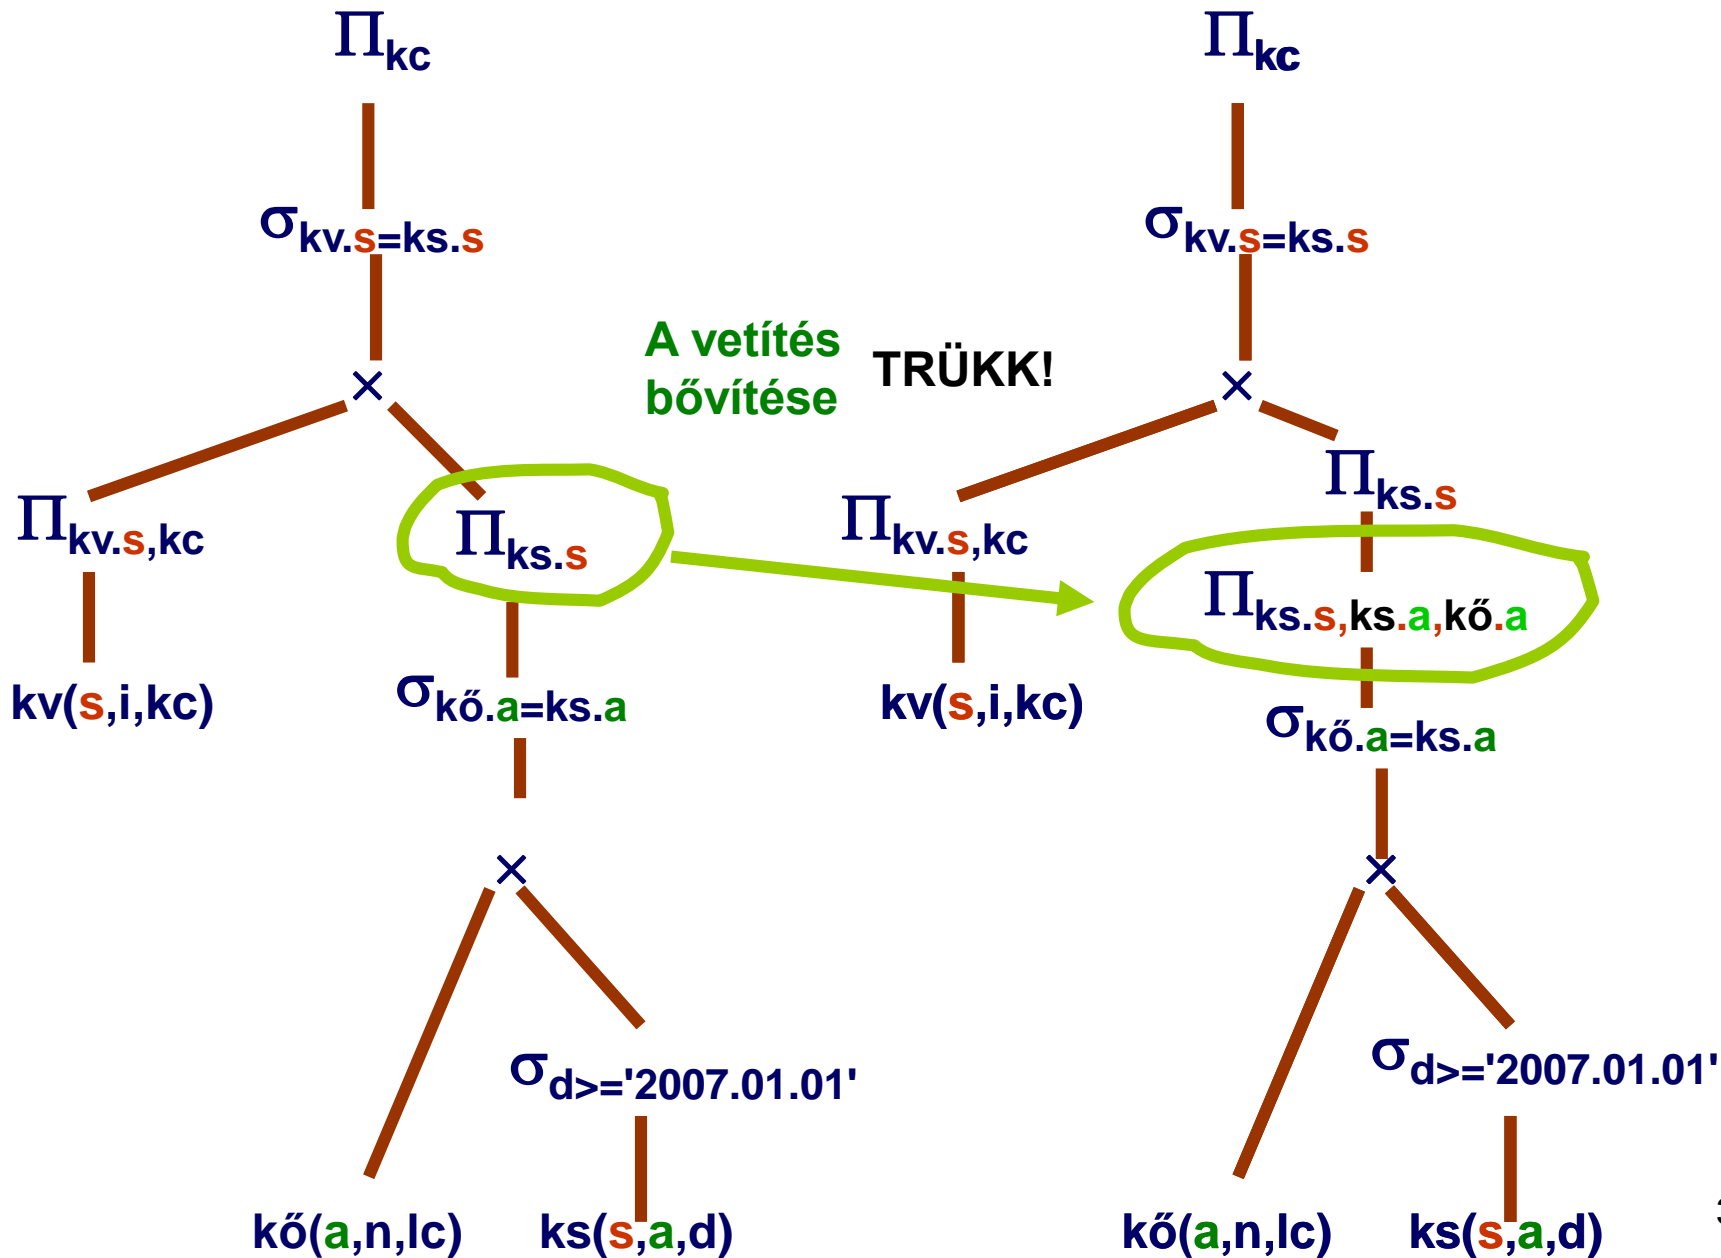
Algebrai optimalizáció



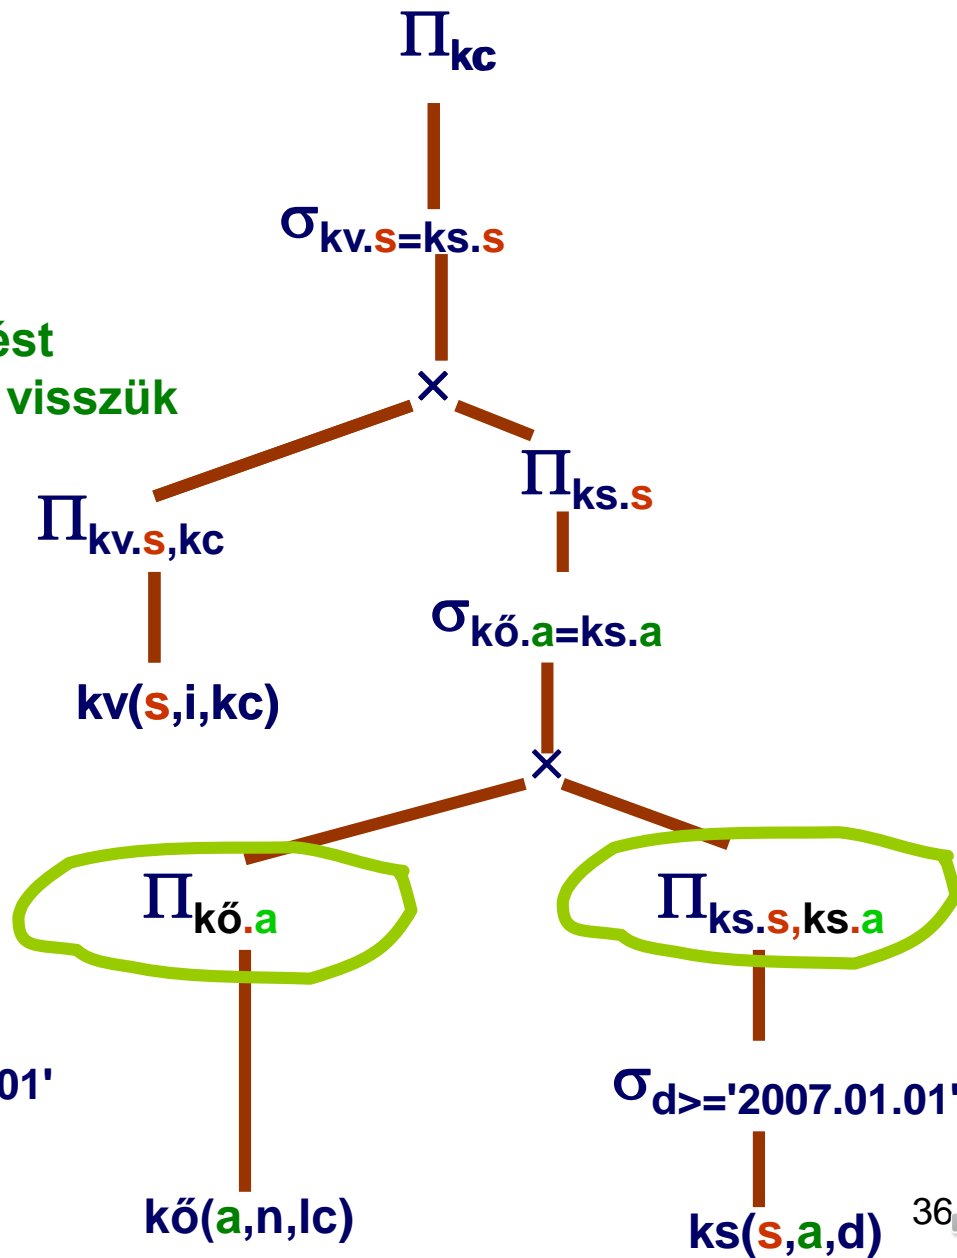

Algebrai optimalizáció



Algebrai optimalizáció



Algebrai optimalizáció



Algebrai optimalizáció


Részgráfokat képezünk (az equi-join miatt a levelekig kiegészítjük a csoportokat)

2. részgráf

Az algebrai optimalizáció eredménye:

Először az 1. részgráfnak megfelelő kifejezést számoljuk ki, és utána a 2. részgráfnak megfelelő kifejezést.

1. részgráf





Köszönöm a figyelmet!