

CYK algoritmus*

1 Chomsky-normálforma, ismételés

Definíció 1.1. Chomsky-normálforma Egy $G = (N, T, P, S)$ környezetfüggetlen grammatikát Chomsky-normálformájúnak nevezünk, ha minden szabálya a következő alakú: $A \rightarrow a$ vagy $A \rightarrow BC$, ahol $a \in T, B, C \in N$.

Tétel 1.1. Minden ε -mentes környezetfüggetlen grammatikához megkonstruálható egy vele ekvivalens Chomsky-normálformájú környezetfüggetlen grammatika.

1. feladat: Határozzuk meg a következő grammatika Chomsky-normálformáját! $G = (\{A, B, S\}, \{a, +, *, (,)\}, P, S)$, P :

$$S \rightarrow A|A + S$$

$$A \rightarrow B|B * A$$

$$B \rightarrow a|(S)$$

Megoldás:

- ε -mentesítés: ✓
- Álterminálisok, hosszredukció:

$$S \rightarrow A|A \underline{X_1 S}$$

$$A \rightarrow B|B \underline{X_2 A}$$

$$B \rightarrow a|X_3 \underline{S X_4}$$

$$X_1 \rightarrow +$$

$$X_2 \rightarrow *$$

*A jegyzet Dr Csuha-Varjú Erzsébet, Dr Tichler Krisztián, Nagy Sára, Veszprémi Anna anyagai alapján készült

$$X_3 \rightarrow ($$

$$X_4 \rightarrow)$$

$$S \rightarrow A|AZ_1$$

$$A \rightarrow B|BZ_2$$

$$B \rightarrow a|X_3Z_3$$

$$Z_1 \rightarrow X_1S$$

$$Z_2 \rightarrow X_2A$$

$$Z_3 \rightarrow SX_4$$

$$X_1 \rightarrow +$$

$$X_2 \rightarrow *$$

$$X_3 \rightarrow ($$

$$X_4 \rightarrow)$$

- Láncztalanítás: láncszabályok: $S \rightarrow A, A \rightarrow B$

$$S \rightarrow BZ_2|a|X_3Z_3|AZ_1$$

$$A \rightarrow a|X_3Z_3|BZ_2$$

$$B \rightarrow a|X_3Z_3$$

$$Z_1 \rightarrow X_1S$$

$$Z_2 \rightarrow X_2A$$

$$Z_3 \rightarrow SX_4$$

$$X_1 \rightarrow +$$

$$X_2 \rightarrow *$$

$$X_3 \rightarrow ($$

$$X_4 \rightarrow)$$

2 CYK algoritmus

A CYK algoritmus (Cocke–Younger–Kasami) egy alulról felfelé elemzést végrehajtó algoritmus, amellyel eldönthető a tartalmazás problémája adott környezetfüggetlen grammatika és szó esetén, azaz adott G grammatika és $u = (u_1 \cdots u_n) \in T^*$ szó esetén eldönti, hogy $u \in^? L(G)$. A grammatikának Chomsky-normálformában kell lennie. Az algoritmus

során egy alsóháromszög mátrixot töltünk ki. A mátrix celláit alulról felfelé, oszlopait balról jobbra számozzuk. Az egyes cellák nemterminális szimbólumokat tartalmaznak.

Az algoritmus lényegében részzavak levezethetőségét vizsgálja, első lépésben az egy szimbólumból álló részzavakat, legutolsó lépésben a teljes szót. A mátrix (i, j) -dik cellájában egy olyan nemterminális szerepel, melyből levezethető az $u_{j,j+i-1}$ részzó, amennyiben ilyen van, egyéként nem szerepel semmi, azaz olyan A nemterminálisok kerülnek melyekre, $A \rightarrow BC \in P$ és B szerepel az (k, j) cellában, C a $(i-k, j+k)$ cellában, valamely $k \in [1..i-1]$. Ez lényegében azt jelenti, hogy B levezeti $u_j \cdots u_k$ -t, C pedig $u_{j+k+1} \cdots u_{j+i-1}$ részzót. Ha a mátrix $(n, 1)$ indexű (bal felső) cellájában megjelenik a start szimbólum, akkor a szó eleme a grammatika által generált nyelvnek.

A CYK algoritmus futási ideje $O(n^3)$. Az első sor kitöltése n lépés, a második $n-1$ a harmadik $2 * (n-2)$, ... , az n . $(n-1) * 1$.

2. feladat: Adott a következő CNF grammatika és az $u = aabbcc$ szó, szemléltessük a CYK algoritmus működését!

$$S \rightarrow AB|BC$$

$$A \rightarrow XA|a$$

$$X \rightarrow a$$

$$C \rightarrow YC|c$$

$$Y \rightarrow c$$

$$B \rightarrow UV|VW$$

$$U \rightarrow XX$$

$$W \rightarrow YY$$

$$V \rightarrow ZZ$$

$$Z \rightarrow b$$

A bemenetként kapott szó hossza 6, így először készítünk egy 6×6 -os táblázatot. Az első sor kitöltésekor 1 hosszúságú részzavak levezetését vizsgáljuk, azaz olyan $A \rightarrow x$ alakú szabályokat keresünk, ahol $A \in N, x \in T$, tehát olyan szabályokat, melyek közvetlenül terminális szimbólumot vezetnek le.

	1	2	3	4	5	6
6						
5						
4						
3						
2						
1	A, X	A, X	Z	Z	C, Y	C, Y
	a	a	b	b	c	c

A második sor kitöltésekor a 2 hosszúságú résszavak levezethetőségét vizsgáljuk. Itt már $A \rightarrow BC$ alakú szabályokkal foglalkozunk. Nézzük meg például, hogyan kaphatjuk meg a 2. sor 3. cellájának értékét. A fenti képleteknek megfelelően a mátrix $(2, 3)$ cellájában olyan nemterminális(ok) szerepel(nek), melyekből levezethető az eredeti szavunk 3. karakterétől kezdődő 2 hosszúságú résszava, azaz $u_{3,4}$. Ekkor tehát olyan $A \rightarrow BC$ szabályokat keresünk, melyre B a mátrix k . sorának j . C pedig a mátrix $i - k$. sorának $j + k$ cellájában szerepel (a sorszám mindig a részszó hosszát, az oszlopszám a részszó első karakterének indexét adja meg). Konkrét értékeket behelyettesítve (figyelembe véve, hogy k most csak 1 lehet) a mátrix $(1, 2)$ és $(2 - 1, 2 + 1)$ celláit vesszük figyelembe. Mindkét cellában Z nemterminális szerepel, tehát olyan szabályt keresünk, melynek jobboldala ZZ , találhatunk is egy ilyen szabályt: $V \rightarrow ZZ$, ennek megfelelően a mátrix $(2, 3)$ cellájába V nemterminális kerül.

	1	2	3	4	5	6
6						
5						
4						
3						
2	A, U	\emptyset	V	\emptyset	C, W	
1	A, X	A, X	Z	Z	C, Y	C, Y
	a	a	b	b	c	c

A harmadik sor kitöltésekor 3 hosszúságú résszavakat vizsgálunk. Most nézzük meg, hogyan tölthetjük ki, a 3. sor 2. celláját! Ekkor tehát a 2. karaktertől kezdődő, 3 hosszúságú részszó levezethetőségét vizsgáljuk ($u_{2,4}$). A képletek alapján (k, j) és $(i - k, j + k)$ cellákat kell figyelnünk, ahol $k \in [1..2]$. Ez azt jelenti, hogy a következő esetek lesznek:

- Ha $k = 1$: $(1, 2)$ és $(2, 3)$ (zöld cellák), ekkor az $(1, 2)$ cellában lévő nemterminális levezeti $u_{2,2}$ -t (a 2. karaktert), a $(2, 3)$ -ban lévő pedig $u_{3,4}$ -et. Olyan szabályokat keresünk tehát, melynek jobboldala AV vagy XV , ilyet azonban nem találunk, úgyhogy egyelőre a $(3, 2)$ cella üresen marad.
- Ha $k = 2$: $(2, 2)$ és $(1, 3)$ (sárga cellák), mivel $(2, 2)$ egy üres cella, biztosan nem lesz találtunk most sem.

A fenti két eset alapján a $(3, 2)$ cella üres marad.

	1	2	3	4	5	6
6						
5						
4						
3	\emptyset	\emptyset	\emptyset	\emptyset		
2	A, U	\emptyset	V	\emptyset	C, W	
1	A, X	A, X	Z	Z	C, Y	C, Y
	a	a	b	b	c	c

A többi sor kitöltése hasonlóan.

	1	2	3	4	5	6
6	S					
5	S	S				
4	B	\emptyset	B			
3	\emptyset	\emptyset	\emptyset	\emptyset		
2	A, U	\emptyset	V	\emptyset	C, W	
1	A, X	A, X	Z	Z	C, Y	C, Y
	a	a	b	b	c	c

A $(6, 1)$ cella képviseli, az 1. karaktertől induló 6 hosszúságú részsztót, ami maga az u szó. Mivel ebben a cellában végül megjelenik a startszimbólum $u \in L(G)$

3. feladat: Adott a 1. feladat CNF grammatikája és az $(a + a) * a$ szó, szemléltessük a CYK algoritmus működését!

	1	2	3	4	5	6	7
7	S						
6	\emptyset	\emptyset					
5	S, A, B	\emptyset	\emptyset				
4	\emptyset	Z_3	\emptyset	\emptyset			
3	\emptyset	S	\emptyset	\emptyset	\emptyset		
2	\emptyset	\emptyset	Z_1	Z_3	\emptyset	Z_2	
1	X_3	S, A, B	X_1	S, A, B	X_4	X_2	S, A, B
	(a	+	a)	*	a

2.1 CYK algoritmus - szintaxis fa

A CYK algoritmust szintaxis fa építésre is használhatjuk. Ehhez megszámozzuk a grammatika szabályait. Ha a mátrix (i, j) cellájában A nemterminális szerepel, amely az $A \rightarrow BC$ szabály baloldala, akkor mellé írjuk a szabály sorszámát, továbbá azt a k számot, amelyre B a mátrix j . oszlopának k . sorában, C pedig a $(j + k)$. oszlop $(i - k)$. sorában szerepel.

Az algoritmus futtatása után a mátrix $(1, 1)$ cellájából indulva az indexek segítségével rekurzívan lépkedve a szintaxis fa felépíthető. Amennyiben egy cellában több nemterminális található, úgy a fa többféleképp is felépíthető, a szó nem egyértelműen áll elő a grammatikából.

Például a következő grammatika és az $u = aaaab$ szó esetén:

Először lejátsszuk az algoritmust, kiegészítve a fentiekkel:

$$S \rightarrow AB^1$$

$$A \rightarrow AA^2|a^3$$

$$B \rightarrow b^4$$

	1	2	3	4	5
5	$S^{4,1}$				
4	$A^{1,2}$	$S^{3,1}$			
3	$A^{1,2}$	$A^{1,2}$	$S^{2,1}$		
2	$A^{1,2}$	$A^{1,2}$	$A^{1,2}$	$S^{1,1}$	
1	$A^{0,3}$	$A^{0,3}$	$A^{0,3}$	$A^{0,3}$	$B^{0,4}$
	a	a	a	a	b

Induljunk ki az $(5, 1)$ cellából, itt azt láthatjuk, hogy az algoritmus futása során $k = 4$ volt, továbbá az 1. szabályt alkalmaztuk $(S \rightarrow AB)$. Ez azt jelenti, hogy a fa gyökere nyilván S lesz, és ennek két gyereke A , valamint B . A kérdés az, hogy a két gyereket a mátrix mely celláiban keressük. Mivel tudjuk, hogy $k = 4$ volt, ebből következik, hogy az első gyerek a mátrix $(4, 1)$ cellájában lesz, a második pedig $(5 - 4 = 1, 1 + 4 = 5)$ cellájában (zöld háttér) lesz. A fa építését ugyanígy ezeken a cellákon keresztül folytatjuk.

Az előálló szintaxisfa, a csúcsokat az adott nemterminális mátrixbeli pozíciója alapján $(sor, oszlop)$ formában címkézzük.

